

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

ESTEFANI APARECIDA RUP ROZA

**ANÁLISE COMPUTACIONAL DA CONFIABILIDADE E INTERPRETABILIDADE
DE MODELOS PREDITIVOS PARA RISCO DE PARTO PREMATURO**

MEDIANEIRA

2026

ESTEFANI APARECIDA RUP ROZA

**ANÁLISE COMPUTACIONAL DA CONFIABILIDADE E INTERPRETABILIDADE
DE MODELOS PREDITIVOS PARA RISCO DE PARTO PREMATURO**

**Computational Analysis of the Reliability and Interpretability of Predictive
Models for Preterm Birth Risk**

Trabalho de Conclusão de Curso de Graduação
apresentado (a) como requisito para obtenção
do título de Bacharel em Ciência da
Computação do Curso de Bacharelado em
Ciência da Computação da Universidade
Tecnológica Federal do Paraná.

Orientador(a): Prof^ª. Alessandra Bortoleto
Garbeloti Hoffman

Coorientador(a): Dr^ª. Nathalia Ferrazzo
Naspolini e Prof. Dr. Davi Pereira Dos Santos.

MEDIANEIRA

2026



[4.0 Internacional](https://creativecommons.org/licenses/by/4.0/)

Esta licença permite compartilhamento, remixe, adaptação e criação a partir do trabalho, mesmo para fins comerciais, desde que sejam atribuídos créditos ao(s) autor(es). Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

Dedico este trabalho à minha família, tanto aquela em que nasci quanto aquela que construí com minhas escolhas. Pelo incentivo a continuar diante das incertezas. Que esta conquista seja prova de esforço, dedicação e luta, não apenas meus, mas de todos que estão comigo, mesmo que não mais fisicamente.

RESUMO

O parto prematuro é um desafio de saúde pública global, responsável por elevadas taxas de mortalidade neonatal e custos hospitalares expressivos. O microbioma vaginal tem sido investigado como fator associado a esse desfecho, e técnicas de Aprendizado de Máquina (AM) têm sido empregadas para identificar biomarcadores microbianos preditivos. Contudo, modelos com maior capacidade preditiva frequentemente comprometem a interpretabilidade, dificultando sua aplicação em contextos clínicos de alto risco. Este trabalho avaliou se ganhos em capacidade preditiva justificam a menor interpretabilidade na identificação de biomarcadores do microbioma vaginal para a predição de Parto Prematuro (PP). Para isso, foram treinados e comparados dois modelos com níveis distintos de transparência, uma Árvore de Decisão (AD) e uma Floresta Aleatória (FA) interpretada via *SHapley Additive exPlanations* (SHAP), utilizando dados públicos do *Microbiome Preterm Birth DREAM Challenge*, compostos por 616 gestantes de 8 coortes. O pré-processamento incluiu seleção da amostra mais precoce por gestante, filtragem de táxons raros, transformação *Centered Log-Ratio* e padronização *z-score*. Na validação cruzada, a FA obteve *Area Under the Receiver Operating Characteristic Curve* (AUROC) de 0,715 e a AD 0,674, uma diferença de aproximadamente 0,04. Na validação independente com coortes não vistas durante o treinamento, ambos os modelos apresentaram queda substancial, com AUROC próximo de 0,51, sendo que a FA sofreu a maior degradação. Três espécies foram consistentemente identificadas como os biomarcadores mais relevantes por ambos os modelos e métodos de interpretação, sendo elas *Peptoniphilus harei*, *Prevotella bivia* e *Lactobacillus iners*. Testes estatísticos com correção para múltiplas comparações confirmaram a significância desses achados, e o teste de permutação validou que ambos os modelos capturam padrões genuínos nos dados. Os resultados indicam que a AD identificou os mesmos biomarcadores centrais que a FA, com desempenho equivalente na validação externa e explicações diretamente acessíveis a partir de sua estrutura, sustentando que a priorização de modelos interpretáveis é uma escolha metodologicamente segura para esse domínio.

Palavras-chave: aprendizado de máquina; microbioma vaginal; parto prematuro; interpretabilidade; biomarcadores.

ABSTRACT

Preterm birth is a global public health challenge, responsible for high neonatal mortality rates and substantial hospital costs. The vaginal microbiome has been investigated as a factor associated with this outcome, and machine learning techniques have been employed to identify predictive microbial biomarkers. However, models with greater predictive capacity often compromise interpretability, hindering their application in high-risk clinical settings. This study assessed whether gains in predictive capacity justify the reduced interpretability in identifying vaginal microbiome biomarkers for preterm birth prediction. Two models with distinct levels of transparency were trained and compared, a AD and a FA interpreted via SHAP, using public data from the *Microbiome Preterm Birth DREAM Challenge*, comprising 616 pregnant women from 8 cohorts. Preprocessing included selection of the earliest sample per participant, rare taxa filtering, *Centered Log-Ratio* transformation, and *z-score* standardization. In cross-validation, the FA achieved an AUROC of 0.715 and the AD 0.674, a difference of approximately 0.04. In independent validation with cohorts unseen during training, both models showed substantial decline, with AUROC near 0.51, with the FA suffering the greatest degradation. Three species were consistently identified as the most relevant biomarkers by both models and both interpretation methods, namely *Peptoniphilus harei*, *Prevotella bivia*, and *Lactobacillus iners*. Statistical tests with correction for multiple comparisons confirmed the significance of these findings, and permutation testing validated that both models capture genuine patterns in the data. Results indicate that the AD identified the same core biomarkers as the FA, with equivalent performance in external validation and explanations directly accessible from its structure, supporting that prioritizing interpretable models is a methodologically sound choice for this domain.

Keywords: machine learning; vaginal microbiome; preterm birth; interpretability; biomarkers.

LISTA DE FIGURAS

Figura 1 – Fluxo de preparação, modelagem e avaliação dos modelos preditivos....	40
Figura 2 – Fluxo de identificação, comparação e consolidação de biomarcadores microbianos.....	41
Figura 3 – Estrutura da AD otimizada na estratégia de amostra precoce (primeiros 4 níveis)	54
Figura 4 – <i>Summary plot</i> do SHAP para a FA otimizada na estratégia de amostra precoce (20 preditores mais relevantes)	56

LISTA DE TABELAS

Tabela 1 – Composição dos conjuntos de dados após filtragem de táxons e pré-processamento, por estratégia de seleção de amostras.....	49
Tabela 2 – Prevalência e abundância relativa de biomarcadores reconhecidos na literatura, por estratégia de seleção de amostras	50
Tabela 3 – Desempenho preditivo dos modelos com hiperparâmetros fixos (referência inicial), por estratégia e ponderação de classes	50
Tabela 4 – Desempenho dos modelos otimizados em validação cruzada	51
Tabela 5 – Comparação de desempenho entre validação cruzada (VC) e validação independente (VI) nas coortes Wayne State e <i>University of California, San Francisco</i> (UCSF)	52
Tabela 6 – Comparação das características populacionais entre os conjuntos de treino e de validação	52
Tabela 7 – Variáveis com importância intrínseca superior a zero na AD otimizada (estratégia de amostra precoce)	53
Tabela 8 – Os 20 preditores com maior importância intrínseca na FA otimizada (estratégia de amostra precoce).....	55
Tabela 9 – Espécies com diferença de abundância estatisticamente significativa entre Parto a Termo (PT) e PP, pelo teste de Mann-Whitney com correção de Benjamini-Hochberg ($q < 0,1$)	58
Tabela 10 – Biomarcadores consolidados: presentes entre os quinze mais relevantes em ao menos um modelo e estatisticamente significativos ($q < 0,1$)..	59
Tabela 11 – Resultado do teste de permutação (1.000 iterações) para os modelos da estratégia de amostra precoce.....	60

LISTA DE QUADROS

Quadro 1 – Comparação de resultados dos trabalhos relacionados	35
Quadro 2 – Estratégias de agregação temporal das amostras avaliadas	48
Quadro 3 – Melhores hiperparâmetros obtidos por busca exaustiva (<i>GridSearch</i>) ...	51
Quadro 4 – Quinze atributos mais relevantes por abordagem de importância (estratégia de amostra precoce)	57

LISTA DE ABREVIATURAS E SIGLAS

16S	16 Svedberg
AD	Árvore de Decisão
AM	Aprendizado de Máquina
AUC	<i>Area Under the Curve</i>
AUPR	<i>Area Under the Precision-Recall Curve</i>
AUROC	<i>Area Under the Receiver Operating Characteristic Curve</i>
BVAB1	<i>Bacterial Vaginosis-Associated Bacterium 1</i>
BWPD	<i>Balance Weighted Phylogenetic Diversity</i>
CARD	<i>Comprehensive Antibiotic Resistance Database</i>
CART	<i>Classification and Regression Trees</i>
CC	Comprimento Cervical
CLR	<i>Centered Log-Ratio</i>
CST	<i>Community State Types</i>
CTF	<i>Compositional Tensor Factorization</i>
DNN	<i>Deep Neural Network</i>
FA	Floresta Aleatória
GL	Glóbulos Brancos
HIV	<i>Human Immunodeficiency Virus</i>
ID3	<i>Iterative Dichotomiser 3</i>
iHMP	<i>Integrative Human Microbiome Project</i>
IMC	Índice de Massa Corporal
KNN	<i>K-Nearest Neighbor</i>
L1	regularização L1
LIME	<i>Local Interpretable Model-agnostic Explanations</i>
LODO	<i>Leave-One-Dataset-Out</i>
LOOCV	<i>Leave-One-Out Cross-Validation</i>
MAGs	<i>Metagenome-Assembled Genomes</i>
MCC	<i>Matthews Correlation Coefficient</i>
MOMS-PI	<i>Multi-Omic Microbiome Study: Pregnancy Initiative</i>
NB	<i>Naïve Bayes</i>
OTUs	<i>Operational Taxonomic Units</i>
pH	potencial Hidrogeniônico
PP	Parto Prematuro
PT	Parto a Termo
RAM	Resistência a AntiMicrobianos

RL	Regressão Logística
rRNA	<i>ribosomal RiboNucleic Acid</i>
S1	Semestre 1
S2	Semestre 2
SHAP	<i>SHapley Additive exPlanations</i>
SUS	Sistema Único de Saúde
SVM	<i>Support Vector Machine</i>
TM7-H1	<i>Bacterial Vaginosis-Associated Bacterium TM7</i>
UCSF	<i>University of California, San Francisco</i>
VB	Vaginose Bacteriana
WGS	<i>Whole Genome Sequencing</i>
XAI	<i>Explainable Artificial Intelligence</i>
XGBoost	<i>eXtreme Gradient Boosting</i>

SUMÁRIO

1	INTRODUÇÃO	12
1.1	Objetivos geral e específicos	12
1.2	Justificativa.....	13
1.3	Estrutura do trabalho.....	15
2	REFERENCIAL TEÓRICO	16
2.1	Parto prematuro e a relação com o microbioma vaginal.....	16
2.1.1	O papel dos microrganismos e sua influência na gravidez	17
2.1.2	Microbioma vaginal e a suas variações	18
2.1.3	Sequenciamento metagenômico.....	19
2.2	Aprendizado de máquina e modelos preditivos em saúde	19
2.2.1	Arquiteturas de modelos e níveis de interpretabilidade	20
2.2.1.1	Modelos transparentes	21
2.2.1.2	Modelos opacos	22
2.2.2	Métodos de explicação <i>post-hoc</i> e limitações	24
2.2.3	Interpretabilidade, explicabilidade e a questão da confiança	25
2.2.4	A falsa dicotomia entre interpretabilidade e precisão	26
2.3	Aprendizado de máquina na predição de parto prematuro.....	26
2.3.1	Desafios de generalização e limitações	27
2.4	Medidas de avaliação e métodos de validação para biomarcadores mi- crobianos e modelos de predição.....	28
2.5	Trabalhos relacionados	30
3	MATERIAIS E MÉTODOS	36
3.1	Materiais	36
3.1.1	Conjunto de dados	36
3.1.2	Ambiente computacional.....	38
3.2	Metodologia	39
3.2.1	Pré-processamento.....	42
3.2.2	Modelagem	43
3.2.3	Avaliação	44
3.2.4	Identificação e comparação de biomarcadores	45
3.2.5	Análise de incerteza e confiabilidade estatística	45
4	RESULTADOS E DISCUSSÃO	47
4.1	Resultados	47
4.1.1	Caracterização e pré-processamento do conjunto de dados	47
4.1.2	Desempenho preditivo dos modelos.....	50
4.1.3	Biomarcadores identificados pelo modelo interpretável	53
4.1.4	Biomarcadores identificados pelo modelo opaco	54
4.1.5	Comparação entre os ranqueamentos de biomarcadores	56
4.1.6	Confiabilidade estatística dos biomarcadores	58
4.2	Discussão	60
4.2.1	Relação entre interpretabilidade e capacidade preditiva	60
4.2.2	Consistência dos biomarcadores frente à literatura.....	62
4.2.3	Confiabilidade das explicações: SHAP versus importância intrínseca	63
4.2.4	Limitações do estudo.....	63
4.2.5	Implicações para o uso clínico	64
5	CONCLUSÃO	66

REFERÊNCIAS..... 68

1 INTRODUÇÃO

O PP é um desafio de saúde pública global, pois sua alta incidência, associada a consequências severas, como mortalidade neonatal e infantil, gera impacto substancial nos sistemas de saúde (Ministério da Saúde, 2024). Apesar dos avanços na medicina materno-infantil, as taxas de prematuridade permanecem estáveis, evidenciando a necessidade de desenvolver métodos mais eficazes de predição e prevenção.

O microbioma vaginal tem recebido destaque como um importante fator relacionado ao parto prematuro. Sua composição desempenha um papel fundamental na saúde urogenital, e desequilíbrios nessa comunidade microbiana têm sido associados a desfechos gestacionais adversos. Devido à complexidade e à alta dimensionalidade dos dados de microbioma, as técnicas de AM oferecem uma abordagem promissora para sua análise. Contudo, a maior capacidade preditiva de modelos mais complexos frequentemente ocorre em detrimento da interpretabilidade, o que impõe desafios importantes para sua adoção em contextos clínicos.

Diante desse cenário, torna-se necessário avaliar o quanto modelos de aprendizado de máquina podem ser compreendidos e confiáveis quando utilizados na predição de parto prematuro. Em diversas situações, modelos mais complexos podem apresentar desempenho ligeiramente superior, porém costumam ser mais difíceis de interpretar, o que torna menos claro como cada decisão é tomada e pode gerar incertezas em contextos clínicos. Para investigar essa questão, são utilizados dados públicos do microbioma vaginal de gestantes, analisando a relação entre essas informações e o tipo de parto. O foco está na verificação da consistência e da confiabilidade das explicações fornecidas pelos modelos. Com isso, busca-se apoiar o uso seguro e responsável de técnicas de aprendizado de máquina em situações sensíveis da área da saúde.

1.1 Objetivos geral e específicos

O objetivo geral deste trabalho é avaliar se métodos interpretáveis poderiam ser adotados como abordagem de primeira linha na identificação de biomarcadores do microbioma vaginal para a predição de parto prematuro, considerando o equilíbrio entre capacidade preditiva e interpretabilidade. Para alcançar essa meta, foram estabelecidos os seguintes objetivos específicos:

- Modelar preditores para classificar o desfecho do parto, incluindo um modelo inerentemente interpretável e outro que requer interpretação *post-hoc*;
- Comparar os microrganismos com maior contribuição para os desfechos de parto em cada uma das abordagens;
- Determinar o grau de incerteza na identificação de microrganismos relevantes, consolidando a detecção de biomarcadores microbianos com confiabilidade estatística;

- Discutir os resultados obtidos pelos diferentes modelos, avaliando a relação entre interpretabilidade, capacidade preditiva e confiabilidade dos biomarcadores.

1.2 Justificativa

O PP, definido como o parto que ocorre antes de 37 semanas completas de gestação, configura-se como um desafio relevante de saúde pública em nível global (Ministério da Saúde, 2024). Em 2020, aproximadamente 13,4 milhões de bebês nasceram prematuros, correspondendo a 9,9% de todos os nascimentos, sem alterações significativas em relação à década anterior (Bradley *et al.*, 2025). No Brasil, a taxa de prematuridade em 2020 foi de 11,3%, mantendo-se elevada e estável ao longo da última década, com mais de 3,5 milhões de casos registrados entre 2012 e 2022 (Ministério da Saúde, 2024). Esses números indicam que, apesar dos avanços em saúde materno-infantil, a prematuridade continua sendo um problema persistente.

As consequências do PP vão além do nascimento antecipado e constituem uma das principais causas de mortalidade infantil no mundo. Em 2020, cerca de 1 milhão de crianças morreram devido a complicações associadas ao parto prematuro (Bradley *et al.*, 2025). Além disso, observa-se forte desigualdade entre países. Em nações de alta renda, a sobrevivência de neonatos extremamente prematuros, com menos de 28 semanas, ultrapassa 90%. Em países de baixa renda, menos de 10% desses bebês sobrevivem. Ao considerar a mortalidade em crianças menores de cinco anos, complicações associadas ao PP representam 17,7% de todas as mortes nesse grupo etário (Perin *et al.*, 2022). Portanto, esses dados mostram que o impacto da prematuridade se estende além do período neonatal, reforçando a necessidade de estratégias de prevenção mais eficazes.

O impacto do PP também envolve custos econômicos significativos. Estudos realizados no contexto do Sistema Único de Saúde (SUS) mostram que os gastos hospitalares aumentam conforme a gravidade da prematuridade (Melo *et al.*, 2022). Prematuros extremos, com menos de 28 semanas, demandam em média R\$ 17.395,46 em cuidados hospitalares. Prematuros moderados, entre 28 e 34 semanas, geram gastos de R\$ 6.688,92, enquanto prematuros tardios, entre 34 e 36 semanas, apresentam custos médios de R\$ 1.120,91. Esses valores demonstram que, além do risco clínico elevado, a prematuridade impõe um ônus financeiro considerável aos sistemas de saúde, o que reforça a necessidade de políticas voltadas para prevenção e intervenção precoce.

Diante desse cenário, os dados epidemiológicos, a alta mortalidade e os custos hospitalares justificam a importância de aprofundar estudos sobre o PP. Nesse sentido, técnicas de AM têm se destacado como alternativas promissoras para analisar fatores associados à prematuridade e apoiar estratégias de prevenção.

Com base em Sharifi-Heris *et al.* (2022), métodos tradicionais utilizados na previsão do PP, como histórico obstétrico, avaliação de fatores de risco maternos e medição do comprimento do colo uterino por ultrassonografia, apresentam desempenho limitado e deixam de identificar

mais da metade dos casos. Assim, técnicas de AM têm sido investigadas como alternativas capazes de explorar registros de saúde com maior profundidade e auxiliar na predição da prematuridade. A mesma revisão aponta que grande parte dos estudos carece de transparência metodológica. Apenas 62% dos trabalhos analisados informaram claramente quais variáveis foram utilizadas como preditoras, o que compromete a reprodutibilidade, a confiabilidade e dificulta a avaliação crítica dos modelos. Dessa forma, embora o desempenho seja relevante, ele não é suficiente para garantir a adequação dos modelos em cenários clínicos.

À luz dessa discussão, Rudin (2019) argumenta que confiar exclusivamente em métodos de explicação pós-treinamento para modelos de caixa-preta envolve riscos, uma vez que tais explicações podem ser imprecisas e não refletir fielmente o funcionamento interno do modelo. A autora ressalta que depender de explicadores externos pode gerar erros adicionais e criar uma falsa sensação de segurança. Assim, em aplicações de alto risco, como saúde, justiça criminal e finanças, modelos transparentes tendem a oferecer maior segurança e clareza.

Apesar desses apontamentos, trabalhos recentes sobre microbioma e prematuridade frequentemente priorizam modelos complexos, como redes neurais e florestas aleatórias, buscando ganhos de desempenho, mas reduzindo a interpretabilidade. Conforme discutido na Seção 2.5, observa-se uma transição de técnicas mais simples e transparentes para abordagens mais sofisticadas e opacas, o que dificulta a identificação dos fatores que influenciam cada predição. Além disso, técnicas como SHAP, embora úteis para identificar padrões gerais, apresentam limitações para representar de forma fiel a importância das variáveis e para apoiar decisões clínicas de maneira confiável (Elshawi; Al-mallah; Sakr, 2021; Rudin *et al.*, 2022). Esse conjunto de limitações reforça a relevância de investigar modelos compreensíveis desde o início.

Considerando o exposto, torna-se essencial avaliar se os supostos ganhos obtidos por modelos complexos justificam a perda de interpretabilidade. Essa análise é fundamental para promover o uso seguro de modelos de AM na prática clínica, especialmente em domínios sensíveis como a saúde materno-infantil.

1.3 Estrutura do trabalho

Este trabalho está organizado em cinco capítulos. O Capítulo 1 apresenta a introdução, onde são expostos a contextualização do tema, a problemática investigada, os objetivos gerais e específicos, a justificativa e esta descrição sobre a estrutura do documento. O Capítulo 2 aborda o referencial teórico, reunindo os principais conceitos relacionados ao aprendizado de máquina, interpretabilidade de modelos, métodos de explicação *post-hoc*, modelos intrinsecamente interpretáveis e estudos correlatos sobre microbioma e parto prematuro. O Capítulo 3 descreve os materiais e métodos utilizados, detalhando o conjunto de dados empregado, os procedimentos de pré-processamento, os modelos de aprendizado de máquina avaliados e a metodologia adotada para a análise de suas interpretações. O Capítulo 4 apresenta os resultados e a discussão, abrangendo a caracterização do conjunto de dados, o desempenho preditivo dos modelos interpretável e opaco, os biomarcadores microbianos identificados por cada abordagem e a avaliação de sua confiabilidade estatística, seguidos da discussão dos achados à luz da literatura. Por fim, o Capítulo 5 encerra o trabalho com as conclusões, retomando os objetivos específicos à luz dos resultados obtidos, apontando as limitações identificadas e indicando direções para trabalhos futuros.

2 REFERENCIAL TEÓRICO

Este capítulo apresenta a base teórica do estudo sobre a confiabilidade de biomarcadores microbianos vaginais na predição do parto prematuro, com foco na utilização de técnicas de AM. A seção inicial discute o emprego de modelos preditivos na área da saúde e o dilema entre precisão e interpretabilidade. Também são abordadas as arquiteturas de modelos e sua importância para a confiabilidade e a transparência necessárias à aplicação de AM em ambientes clínicos de alto risco.

Avançando na contextualização, o capítulo aprofunda a relação entre o parto prematuro e as características do microbioma vaginal, abordando o papel dos microrganismos na gestação e os impactos das alterações na composição microbiana. Adicionalmente, são revisados os desafios e as limitações das técnicas de AM na predição do parto prematuro, considerando a alta dimensionalidade e a complexidade dos dados metagenômicos. Por fim, será apresentada uma revisão de trabalhos correlatos, situando esta pesquisa no cenário científico atual e destacando as lacunas que este estudo busca preencher ao comparar a confiabilidade das interpretações de diferentes modelos preditivos.

2.1 Parto prematuro e a relação com o microbioma vaginal

O PP, definido como o nascimento antes de 37 semanas completas de gestação, constitui um dos maiores desafios da perinatologia mundial (Gudnadottir *et al.*, 2022). Por ser o principal determinante da mortalidade e morbidade neonatal, além de acarretar consequências adversas ao longo da vida dos recém-nascidos acometidos por essa condição, evidencia-se o impacto significativo do parto prematuro na saúde (Beck *et al.*, 2010). Estima-se que mais de um terço de todas as mortes neonatais no mundo estejam diretamente relacionadas a complicações do PP, o qual também se associa fortemente a repercussões que se estendem ao longo da vida (Bradley *et al.*, 2025). Nesses casos, as taxas de paralisia cerebral, deficit sensorial, dificuldades de aprendizagem e doenças respiratórias são mais elevadas, estando ainda relacionadas a condições cardiovasculares adversas e comprometimento do neurodesenvolvimento (Beck *et al.*, 2010; Bradley *et al.*, 2025).

A etiologia desse desfecho permanece complexa e não totalmente entendida, sendo considerada multifatorial (Beck *et al.*, 2010). Segundo Fettweis *et al.* (2019), infecções genitais e urinárias, bem como a inflamação induzida por microrganismos, configuram causas relevantes, estando associadas a aproximadamente 40% a 50% dos casos de PP. O autor descreve dois principais mecanismos pelos quais os microrganismos podem contribuir para esse desfecho. O primeiro é a via ascendente, em que bactérias presentes no trato reprodutivo inferior migram em direção ao útero, alcançando as membranas fetais e a placenta. O segundo envolve a disseminação hematogênica, pela qual patógenos orais, como aqueles associados à doença periodontal, podem atingir a corrente sanguínea materna e, posteriormente, o ambiente intrau-

terino. Contudo, embora as possíveis relações entre o microbioma oral e o parto prematuro também tenham sido investigadas, esse eixo não constitui o foco do presente estudo.

2.1.1 O papel dos microrganismos e sua influência na gravidez

O papel dos microrganismos presentes na vagina, coletivamente denominados microbioma vaginal, é fundamental para a manutenção da saúde reprodutiva feminina, pois atuam na regulação do ambiente local e na sua proteção (Fettweis *et al.*, 2019). Esse microbioma é, em geral, caracterizado pelo predomínio de diferentes espécies de *Lactobacillus*, responsáveis pela produção de ácido láctico a partir do metabolismo do glicogênio liberado pelo epitélio vaginal principalmente sob influência do hormônio estrogênio (Chu *et al.*, 2018). Como consequência, o potencial Hidrogeniônico (pH) é mantido abaixo de 4,5, condição que inibe o crescimento e a colonização de microrganismos potencialmente patogênicos, como bactérias anaeróbias e fungos associadas a Vaginose Bacteriana (VB) e ao *Human Immunodeficiency Virus* (HIV) (Witkin, 2015).

Segundo Witkin (2015), o isômero ácido D-láctico, produzido por cepas como *Lactobacillus crispatus*, *L. gasseri* e *L. jensenii*, exerce papel fundamental na proteção contra a invasão microbiana do trato genital superior. Esse metabólito atua na preservação da barreira cervical, cuja integridade é essencial para restringir a migração de microrganismos em direção ao endométrio e à cavidade amniótica. Portanto, a proteção dessa barreira é muito importante, pois reduz o risco de infecções intrauterinas e complicações que são associadas ao PP.

Dentre os lactobacilos, pesquisas têm indicado que o aumento de *Lactobacillus iners* pode estar associado ao PP (Chakoory *et al.*, 2024; Freitas *et al.*, 2020; Huang *et al.*, 2023). Esse microrganismo apresenta um genoma reduzido e codifica um número limitado de enzimas, resultando em menor produção de ácido láctico (Witkin, 2015). Dessa forma, sua presença não promove uma redução significativa do pH vaginal, o que o torna mais permissivo ao estabelecimento de uma microbiota mais diversa, possibilitando a colonização por microrganismos frequentemente relacionados a desfechos adversos (Chu *et al.*, 2018).

Assim, quando a produção de ácido láctico pelos lactobacilos é insuficiente para garantir a acidez adequada do ambiente vaginal, ocorre uma elevação do pH local. Essa alteração favorece a proliferação de bactérias anaeróbias oportunistas, que se aproveitam do desequilíbrio para colonizar a mucosa (Witkin, 2015). Dentre essas bactérias estão a *Gardnerella vaginalis* e *Prevotella*, frequentemente associadas a casos de VB (Chakoory *et al.*, 2024; Fettweis *et al.*, 2019; Freitas *et al.*, 2020; Golob *et al.*, 2024; Huang *et al.*, 2023; Park *et al.*, 2022). Isso ocorre porque a redução das concentrações de ácido láctico, associada ao aumento de ácidos graxos de cadeia curta, modifica o equilíbrio do microambiente vaginal diminuindo a atividade protetora e estimulando a produção de citocinas pró-inflamatórias (Fettweis *et al.*, 2019). Portanto, esse processo favorece inflamações locais, capazes de comprometer a integridade das barreiras de defesa do trato genital e aumentar risco de complicações, como o PP (Gudnadottir *et al.*, 2022).

2.1.2 Microbioma vaginal e a suas variações

A composição do microbioma vaginal varia de forma consistente entre diferentes grupos populacionais. Por exemplo, mulheres de ascendência europeia geralmente apresentam comunidades vaginais dominadas por *Lactobacillus crispatus*, enquanto mulheres de ascendência africana e hispânica tendem a ter maior diversidade bacteriana com menor presença de lactobacilos, predominando *Lactobacillus iners* (Hyman *et al.*, 2014). Populações de ascendência asiática mostram perfis intermediários, com variação na abundância e composição de lactobacilos (Chu *et al.*, 2018). Essas variações reforçam que características étnicas podem influenciar de maneira significativa a estrutura das comunidades microbianas, o que precisa ser levado em conta nas análises comparativas.

Além disso, diversos estudos sobre o microbioma vaginal adotam delineamentos longitudinais, com a coleta de múltiplas amostras da mesma gestante em diferentes períodos da gravidez (Fettweis *et al.*, 2019; Liao *et al.*, 2023; Huang *et al.*, 2023; Golob *et al.*, 2024). Esse tipo de abordagem possibilita a avaliação das mudanças temporais na composição microbiana ao longo da gestação, permitindo identificar padrões de estabilidade ou variação associados tanto à progressão gestacional quanto a desfechos obstétricos adversos.

De acordo com Chu *et al.* (2018), o estado hormonal e fisiológico da pessoa gestante sofre remodelações que provocam alterações significativas na flora vaginal. Observa-se, por exemplo, o aumento da deposição de glicogênio, resultado dos elevados níveis de estrogênio, o que favorece a proliferação de lactobacilos. Consequentemente, o microbioma vaginal tende a se tornar mais estável durante a gestação, apresentando redução na riqueza e na diversidade de espécies bacterianas.

Ademais, a vagina não é microbiologicamente homogênea. Diferentes regiões podem apresentar composições bacterianas distintas, de modo que o local da amostragem torna-se um fator crítico, capaz de influenciar significativamente os resultados obtidos (Hyman *et al.*, 2014).

No estudo do microbioma, utilizam-se dois conceitos principais de diversidade. A diversidade alfa refere-se à diversidade de espécies dentro de uma única amostra ou comunidade, considerando tanto o número total de táxons diferentes quanto a uniformidade na abundância relativa entre as espécies (Hyman *et al.*, 2014). Sendo assim, uma baixa diversidade alfa é considerada saudável pois indica que a comunidade é dominada por uma única espécie protetora, geralmente do gênero *Lactobacillus* (Gudnadottir *et al.*, 2022). Por outro lado, a diversidade alfa significativamente mais alta é observada em amostras de mulheres que vieram a ter PP (Fettweis *et al.*, 2019). A diversidade beta é a medida de diversidade entre as amostras, responsável por quantificar a diferença ou similaridade na composição microbiana entre mais de uma comunidade (Chu *et al.*, 2018). Valores baixos de diversidade beta indicam que as comunidades microbianas são mais semelhantes entre si, refletindo maior estabilidade, enquanto valores mais altos sugerem maior variação entre os grupos analisados.

2.1.3 Sequenciamento metagenômico

O estudo do microbioma tem sido auxiliado por abordagens de sequenciamento metagenômico, que permitem a identificação e caracterização de comunidades microbianas. Os avanços nas tecnologias de sequenciamento revolucionaram a identificação de bactérias e suas comunidades, superando as limitações das técnicas de cultura tradicionais que se concentram apenas em organismos bem caracterizados e cultiváveis (Hyman *et al.*, 2014).

De acordo com Chu *et al.* (2018), o sequenciamento do gene 16 *Svedberg* (16S) *ribosomal RiboNucleic Acid* (rRNA) permite a classificação de bactérias até o nível de gênero e espécie, apresentando a vantagem de ser menos dispendioso. O autor também discute o sequenciamento metagenômico completo (*Whole Shotgun*), que possibilita classificações mais precisas, incluindo identificação de cepas individuais, além de fornecer informações funcionais e metabólicas das comunidades microbianas. Entretanto, esse método é mais caro e requer maiores recursos computacionais.

As instâncias geradas pelo sequenciamento permitem análises quantitativas e qualitativas, incluindo a identificação de quais microrganismos estão presentes e sua abundância relativa, a comparação de diversidades alfa e beta, a detecção de cepas específicas e a identificação de biomarcadores microbianos, bem como a investigação de funções metabólicas e vias genéticas. Além disso, essas instâncias podem ser utilizadas na construção de modelos preditivos para desfechos clínicos. Dessa forma, essa base de dados pode ser explorada para compreender a estrutura, função e dinâmica das comunidades microbianas, inclusive no contexto do PP.

2.2 Aprendizado de máquina e modelos preditivos em saúde

O AM pode ser compreendido como o campo da inteligência artificial dedicado ao desenvolvimento de modelos capazes de identificar padrões em dados, com o propósito de realizar predições ou revelar estruturas subjacentes (Greener *et al.*, 2022). De uma perspectiva técnica, esses modelos podem ser vistos como funções matemáticas que operam sobre um conjunto de características de entrada (*features*) e produzem um ou mais rótulos (*labels*) como saída (Greener *et al.*, 2022; Rajkomar; Dean; Kohane, 2019). Assim, um componente central do modelo são os parâmetros ajustáveis, cujos valores são otimizados durante o treinamento. De forma geral, esse processo é definido pelo algoritmo de AM, que estabelece as regras de ajuste dos parâmetros, enquanto o modelo treinado é o resultado final desse processo, utilizado para aplicar o conhecimento adquirido e mapear novas entradas em seus respectivos rótulos.

Ademais, o AM dispõe de algoritmos adequados a distintos contextos, como o aprendizado supervisionado, não supervisionado e por reforço, cuja aplicação depende do tipo de problema e das características dos dados. No caso do aprendizado supervisionado, o modelo observa exemplos de pares de entrada e saída e aprende a função que realiza o mapeamento entre eles, generalizando o conhecimento para realizar predições coerentes em dados nunca

vistos (Russell; Norvig, 2022). Nesse caso, a classificação consiste em treinar um algoritmo para atribuir cada item a uma categoria específica, com base em exemplos previamente rotulados, de modo que ele consiga realizar previsões corretas quando aplicado a dados inéditos (Hariom; Puri; Lookabaugh, 2024).

No presente trabalho, a previsão do desfecho do parto será abordada por meio de técnicas de classificação, utilizando dados do microbioma vaginal para inferir se o parto será PT ou PP. Para isso, é necessário selecionar um ou mais algoritmos preditivos adequados, definir protocolos de avaliação de desempenho e medidas de otimização, considerando as características específicas dos dados do microbioma, como alta dimensionalidade (Luo *et al.*, 2016).

A principal utilidade do AM está na sua capacidade de lidar com conjuntos de dados altamente complexos, que ultrapassam a capacidade cognitiva humana (Faceli *et al.*, 2025). Diferentemente da programação tradicional, baseada em regras explícitas, os modelos de AM aprendem a partir de exemplos, sendo especialmente valiosos quando as relações subjacentes nos dados são complexas ou pouco conhecidas (Greener *et al.*, 2022). Essa capacidade permite prever desfechos clínicos, identificar pacientes em risco elevado e apoiar decisões médicas mais precisas, contribuindo para diagnósticos rápidos e personalizados (Russell; Norvig, 2022). Portanto, o AM se apresenta como uma ferramenta estratégica para aprimorar a prática clínica e potencializar avanços na pesquisa.

2.2.1 Arquiteturas de modelos e níveis de interpretabilidade

De acordo com Rudin *et al.* (2022), a arquitetura de um modelo de AM pode ser compreendida como a forma estrutural que organiza seus cálculos e restrições, influenciando diretamente em sua transparência. Dessa forma, a escolha arquitetural não se limita apenas a um aspecto técnico, mas também configura uma decisão estratégica que equilibra aspectos essenciais como desempenho e interpretabilidade.

Conforme destacam Faceli *et al.* (2025), os métodos simbólicos distinguem-se por representar o conhecimento extraído dos dados por meio de estruturas compreensíveis, como regras, árvores de decisão ou expressões lógicas. Essa forma de representação favorece a transparência e a rastreabilidade das decisões algorítmicas, aspectos essenciais em contextos clínicos, nos quais é necessário justificar recomendações e apoiar o raciocínio médico. No entanto, ao buscar aprimorar o desempenho por meio da combinação de diferentes modelos simbólicos, ocorre um aumento na complexidade estrutural, o que exige estratégias adicionais para preservar a clareza interpretativa.

A relação de compromisso entre interpretabilidade e precisão é um tema central e recorrente em AM, especialmente em aplicações de alto risco como na área da saúde (Greener *et al.*, 2022; Rudin, 2019). Essencialmente, esse dilema descreve a tendência de que, à medida que a complexidade de um modelo aumenta para alcançar maior precisão preditiva, sua acurácia descritiva tende a diminuir, uma vez que se torna mais difícil compreender de forma objetiva as relações aprendidas (Murdoch *et al.*, 2019). O cerne dessa questão está diretamente

relacionado à natureza dos diferentes tipos de modelos de AM, o que justifica a análise de suas arquiteturas nas próximas seções.

2.2.1.1 Modelos transparentes

Os modelos transparentes são aqueles cuja estrutura lógica de decisão apresenta um nível de simplicidade que permite a interpretação direta por humanos. Por essa razão, são frequentemente chamados de modelos “caixa de vidro” ou “caixa branca”, pois todos os seus parâmetros são conhecidos e é possível acompanhar exatamente como o modelo chega a uma conclusão (Rudin *et al.*, 2022).

Assim, a capacidade de serem compreendidos é uma característica inerente à sua estrutura, não necessitando de métodos adicionais para explicar suas previsões. Com isso, são mais fáceis de depurar e aptos a solucionar problemas, permitindo que especialistas do domínio, como médicos, verifiquem o raciocínio do modelo, identifiquem vieses e decidam se confiam ou não em uma previsão (Rudin *et al.*, 2022; Hulsen, 2023).

Ainda que a interpretabilidade ofereça vantagens significativas, é necessário cautela quanto à robustez e à generalização dos resultados em contextos mais complexos. Quando aplicados em sistemas de maior escala, que integram grandes volumes de dados de pacientes provenientes de diferentes instituições, esses modelos podem apresentar desempenho limitado diante da elevada complexidade dos dados clínicos e da diversidade de pacientes e diagnósticos (Stiglic *et al.*, 2020).

Entre os exemplos clássicos de modelos transparentes destacam-se a regressão linear e logística, vizinhos mais próximos (*k-nearest neighbors*), modelos bayesianos, bem como árvores de decisão e modelos baseados em regras, todos considerados intrinsecamente interpretáveis (Hulsen, 2023).

As árvores de decisão se consolidaram como uma das estruturas mais utilizadas em AM, tanto pela clareza interpretativa quanto pela versatilidade em tarefas de classificação e regressão (Salzberg, 1994). Seu funcionamento baseia-se em uma sequência de testes condicionais aplicados às variáveis de entrada, nos quais cada nó interno representa uma condição, os ramos indicam os possíveis resultados e as folhas correspondem às previsões finais (Russell; Norvig, 2022; Murdoch *et al.*, 2019; Rudin *et al.*, 2022). Nela, cada caminho da raiz até uma folha corresponde a uma regra do tipo se-então, o que facilita a interpretação das decisões. Além disso, como destacado por Faceli *et al.* (2025), tais modelos adotam a estratégia de dividir para conquistar, decompondo problemas complexos em subproblemas menores e mais manejáveis.

Apesar da sua simplicidade conceitual, algoritmos clássicos como o *Iterative Dichotomiser 3* (ID3) (Quinlan, 1986), o *Classification and Regression Trees* (CART) (Breiman *et al.*, 1984) e o *C4.5* (Quinlan, 2014) desempenharam papel fundamental na consolidação das árvores de decisão como ferramenta central em AM. O ID3, proposto por Quinlan (1986), destacou-se pelo uso da entropia e do ganho de informação como critérios de divisão. O CART, por sua vez, introduziu a ideia de árvores binárias para classificação e regressão, além de mecanismos de

poda orientados por custo-complexidade, influenciando diretamente o desenvolvimento subsequente. Já o *C4.5*, sucessor do ID3, ampliou suas capacidades ao lidar com atributos contínuos, valores ausentes e estratégias mais robustas de poda, características que o tornaram amplamente aplicado em domínios reais (Quinlan, 2014). Assim, é possível compreender a existência de diferentes algoritmos que buscam aplicar o conceito das árvores de decisão de maneiras variadas.

Esses algoritmos pioneiros consolidaram as árvores de decisão como modelos centrais no AM e forneceram as bases para métodos posteriores. Inseridos na tradição da indução descendente, característica da família de algoritmos *Top-Down Induction of Decision Trees*, eles forneceram a estrutura essencial que ainda sustenta técnicas, como FA e *Gradient Boosted Trees*, que mantêm a lógica de divisão recursiva enquanto incorporam estratégias adicionais de robustez e generalização (Quinlan, 1986; Breiman, 2001a).

2.2.1.2 Modelos opacos

Em AM, alguns algoritmos são frequentemente percebidos como uma "caixa preta", pois a lógica interna que conduz suas decisões não é facilmente compreensível (Hulsen, 2023). Essa opacidade, quando combinada à inconsistência e ao relato inadequado das fontes de dados e dos processos de modelagem, torna os resultados de muitos estudos biomédicos difíceis de interpretar, podendo gerar conclusões equivocadas e comprometer a credibilidade até mesmo de pesquisas válidas (Luo *et al.*, 2016).

Dentre suas características, é possível mencionar estruturas matemáticas e algorítmicas intrinsecamente complexas, responsáveis por potencializar a capacidade de gerar modelos capazes de aprender padrões estatísticos altamente sofisticados e heterogêneos e, quando bem treinados, apresentam melhor capacidade de generalização em problemas complexos (Rajkumar; Dean; Kohane, 2019; Luo *et al.*, 2016). Contudo, sua opacidade torna difícil explicar padrões sutis por trás de uma previsão específica, sendo mais difíceis de depurar, o que, segundo Rudin *et al.* (2022), é problemático com dados médicos.

Por não ser trivial rastrear o processo de decisão de um modelo, vieses presentes nos dados podem permanecer ocultos, levando-o a aprender a “resposta certa pelos motivos errados”, fenômeno conhecido como *Clever Hans* (Rudin *et al.*, 2022). O termo faz referência a um cavalo do início do século XX que aparentemente resolvia cálculos matemáticos, mas que na realidade apenas respondia a sinais involuntários emitidos por seu treinador, ficando evidente que não havia compreensão genuína da tarefa (Eysenck; Eysenck, 2023). De forma análoga, modelos de inteligência artificial podem apresentar alto desempenho em determinadas tarefas sem realmente capturar os conceitos subjacentes, apoiando-se em correlações errôneas presentes nos dados. Embora todos os modelos possam recorrer a heurísticas superficiais, aqueles com maior interpretabilidade permitem identificar corretamente quando o aprendizado ocorre pelos motivos adequados, o que não é possível em modelos opacos sem o auxílio de ferramentas específicas.

Segundo Greener *et al.* (2022), exemplos de modelos de AM opacos incluem máquinas de vetor de suporte, modelos de conjunto como florestas aleatórias e aprendizado por reforço em gradiente (por exemplo, *eXtreme Gradient Boosting* (XGBoost)). Além disso, diversas arquiteturas de redes neurais, como redes profundas, perceptrons multicamadas, redes convolucionais, redes recorrentes e de codificação automática também se enquadram nessa categoria.

Assim, as florestas aleatórias se destacam como uma das técnicas de maior uso em problemas de classificação e capacidade de lidar com dados de alta dimensionalidade (Greener *et al.*, 2022). Elas pertencem a uma classe de modelos baseados em *ensemble*, que combinam múltiplos modelos mais simples para obter uma previsão mais precisa e estável (Niu *et al.*, 2025).

A ideia de introduzir aleatoriedade na construção de árvores tem origem no método de subespaços aleatórios, proposto por Ho (1995), que consistia em treinar diferentes árvores em subconjuntos do espaço de atributos. Essa abordagem visava aumentar a diversidade entre os classificadores e, conseqüentemente, melhorar a capacidade de generalização do modelo (Ho, 1995). Posteriormente, a técnica foi formalizada por Breiman (2001a) ao combinar o princípio do *bagging*¹ com a seleção aleatória de atributos em cada nó da árvore. Nessa abordagem, diversas árvores de decisão são construídas a partir de amostras do conjunto de treinamento e, posteriormente, suas predições são agregadas por votação ou média, sem a necessidade de poda (Faceli *et al.*, 2025).

Segundo Greener *et al.* (2022), além do bom desempenho em tarefas de classificação e regressão, as florestas aleatórias possuem ainda a vantagem de demandar um processo de ajuste de hiperparâmetros menos complexo quando comparadas a modelos mais sofisticados, como as redes neurais profundas. Essa característica contribui para sua ampla adoção, uma vez que permite alcançar resultados competitivos sem a necessidade de processos extensos de otimização, tornando-as uma alternativa eficiente tanto em termos de implementação quanto de custo computacional.

Apesar do desempenho robusto em diferentes contextos, por se tratar de um modelo baseado em *ensemble*, a compreensão direta de seu funcionamento não é trivial, o que faz com que sejam enquadradas como modelos opacos que demandam explicações adicionais (Hulsen, 2023). Essa característica se insere no debate mais amplo sobre modelos caixa-preta, cuja complexidade pode dificultar a verificação de vieses, a detecção de erros e a análise de justiça nos resultados, especialmente em domínios críticos como saúde (Rudin *et al.*, 2022).

No entanto, é importante destacar que, mesmo não sendo modelos totalmente transparentes, as florestas aleatórias podem ser interpretadas por meio de técnicas específicas aplicadas em diferentes níveis. Essas abordagens incluem a interpretabilidade local, que busca justificar a decisão em instâncias individuais, e a interpretabilidade global, voltada para a com-

¹ Segundo Faceli *et al.* (2025), *bagging* (Bootstrap Aggregating) consiste em treinar vários modelos em réplicas do conjunto de dados geradas por reamostragem com reposição, agregando depois suas predições por votação ou média.

preensão do comportamento agregado do modelo (Stiglic *et al.*, 2020). Assim, são frequentemente apoiadas por métodos *post-hoc* para ampliar sua explicabilidade em contextos críticos.

2.2.2 Métodos de explicação *post-hoc* e limitações

Os métodos *post-hoc* buscam aproximar o comportamento de modelos opacos por meio de modelos substitutos ou técnicas adicionais, como a extração de regras ou o destilamento de conhecimento (Stiglic *et al.*, 2020). A área de *Explainable Artificial Intelligence* (XAI) avançou justamente para responder à necessidade de tornar esses modelos compreensíveis. Assim, diferentes estratégias ganharam destaque por permitirem identificar a contribuição de variáveis individuais nas predições, seja em escala global, fornecendo um ranqueamento geral de importância, seja em escala local, explicando predições específicas.

Entre as técnicas mais conhecidas está o *Local Interpretable Model-agnostic Explanations* (LIME), que gera explicações locais ao criar modelos lineares simplificados em torno de uma predição específica, aproximando o comportamento do modelo original em uma vizinhança restrita da instância analisada (Ribeiro; Singh; Guestrin, 2016).

Outra técnica amplamente adotada é o SHAP, proposto por (Lundberg; Lee, 2017), que se fundamenta nos valores de *Shapley* da teoria dos jogos cooperativos. O princípio central do SHAP consiste em tratar cada atributo de entrada como um “jogador” em um jogo cooperativo, onde o resultado é a predição do modelo. Para cada predição individual, o SHAP calcula a contribuição marginal de cada atributo, considerando todas as combinações possíveis de atributos presentes e ausentes. Dessa forma, cada variável recebe um valor que indica o quanto ela contribuiu para que a predição se afastasse do valor médio esperado, podendo ser positivo (aumenta a probabilidade do desfecho) ou negativo (diminui a probabilidade). A soma dos valores SHAP de todos os atributos, somada ao valor base do modelo, reproduz exatamente a predição final, o que garante consistência matemática. Quando os valores SHAP absolutos são agregados sobre todas as amostras, obtém-se uma medida de importância global de cada atributo, permitindo a construção de ranqueamentos de relevância (Lundberg; Lee, 2017; Papoutsoglou *et al.*, 2023).

É importante distinguir a importância obtida via SHAP daquela obtida de forma intrínseca em modelos baseados em árvores. A importância intrínseca, como a disponível em árvores de decisão, mede a redução média de impureza (Gini ou entropia) proporcionada por cada atributo ao longo das divisões do modelo. Essa medida é uma propriedade direta da estrutura do modelo treinado. Já o SHAP calcula a contribuição marginal de cada atributo para cada predição individual, considerando interações entre variáveis. Ambas as abordagens podem gerar ranqueamentos diferentes para os mesmos dados, o que torna sua comparação relevante para avaliar a robustez dos biomarcadores identificados (Niu *et al.*, 2025).

Apesar dos avanços alcançados, os métodos de explicabilidade ainda apresentam limitações importantes, como a produção de explicações inconsistentes entre abordagens e a dificuldade em identificar se o erro se origina do modelo original ou do modelo explicativo, o que

evidência que, em muitos casos, as justificativas fornecidas não refletem o funcionamento real do algoritmo (Rudin *et al.*, 2022). Em contextos críticos, como na saúde, confiar exclusivamente em explicações *post-hoc* pode ser arriscado, pois nem sempre elas garantem justiça, robustez ou adequação da decisão automatizada (Hulsen, 2023).

Assim, a literatura indica que esses métodos devem ser encarados com cautela. É inegável que eles cumprem um papel relevante na avaliação preliminar dos modelos, mas não são tratados como uma solução definitiva.

2.2.3 Interpretabilidade, explicabilidade e a questão da confiança

A discussão sobre interpretabilidade e explicabilidade em modelos de AM emerge como um dos pontos centrais para compreender sua confiabilidade, sobretudo em cenários de alto impacto, como o setor da saúde. Stiglic *et al.* (2020) enfatizam que a interpretabilidade possui uma dimensão subjetiva, o que dificulta estabelecer definições e medidas padronizadas. Por sua vez, Miller (2019) oferece uma definição que caracteriza a interpretabilidade como a capacidade de um ser humano compreender os motivos que levaram um modelo a produzir determinada decisão. Dessa forma, qualquer reflexão crítica sobre interpretabilidade precisa considerar tanto a dificuldade de consenso quanto a necessidade de clareza para o usuário final.

Já a explicabilidade se refere à capacidade de um modelo, mesmo que opaco, fornecer justificativas ou razões que permitam ao usuário compreender suas decisões (Saraswat *et al.*, 2022; Hulsen, 2023). Essa distinção é relevante porque modelos interpretáveis fornecem compreensão intrínseca, enquanto modelos explicáveis dependem de camadas auxiliares de análise para tornar suas decisões compreensíveis. Em cenários de alto risco, como saúde, confiar em explicações aproximadas pode ser arriscado, pois podem não refletir completamente o raciocínio do modelo (Rudin *et al.*, 2022).

A confiança nos modelos de AM depende tanto da interpretabilidade quanto da explicabilidade. Quando o modelo é interpretável, sua lógica interna é acessível e compreensível, permitindo que profissionais verifiquem diretamente como as entradas determinam as saídas. Em modelos complexos, a confiança se apoia na capacidade de gerar explicações *post-hoc* confiáveis, que traduzam decisões opacas em justificativas compreensíveis (Ribeiro; Singh; Guestrin, 2016; Saraswat *et al.*, 2022; Hulsen, 2023).

No contexto médico, muitos algoritmos apresentam elevada complexidade, o que dificulta que profissionais avaliem os resultados de forma segura, restringindo a adoção dessas ferramentas (Stiglic *et al.*, 2020). Além disso, estudos evidenciam que a falta de transparência pode resultar em vieses significativos, como diferenças raciais em decisões clínicas, observadas quando modelos reproduzem desigualdades históricas presentes nos dados. Tais situações reforçam a importância de modelos interpretáveis, uma vez que apenas soluções transparentes permitem identificar, compreender e mitigar esses vieses, evitando impactos éticos e sociais relevantes (Obermeyer *et al.*, 2019; Rudin, 2019).

Dessa forma, a interpretabilidade e a explicabilidade são condições complementares e necessárias para que os usuários possam confiar nas predições. Enquanto a interpretabilidade refere-se à compreensão direta da lógica interna do modelo, característica intrínseca a algoritmos transparentes, a explicabilidade envolve o uso de métodos adicionais que tornam compreensíveis os resultados de modelos mais complexos ou opacos. Assim, ambas permitem que profissionais avaliem, aceitem ou questionem as recomendações com base em justificativas claras e fundamentadas.

2.2.4 A falsa dicotomia entre interpretabilidade e precisão

A percepção de que interpretabilidade e acurácia preditiva estariam em conflito nos modelos de AM aparece com frequência nas discussões sobre o tema (Holzinger *et al.*, 2019). Contudo, essa formulação tende a simplificar em excesso a questão e a negligenciar evidências contrárias. Rudin *et al.* (2022) argumenta que a suposta necessidade de escolher entre precisão e interpretabilidade configura uma falsa dicotomia, uma vez que não há comprovação consistente de que modelos interpretáveis apresentem desempenho inferior em relação aos modelos de natureza opaca.

Breiman (2001b) critica a crença tradicional de que modelos mais simples são necessariamente superiores, princípio conhecido como Navalha de Occam, argumentando que essa visão não se sustenta em contextos preditivos. O autor denomina essa tensão de “dilema de Occam”, ao apontar que, embora modelos simples sejam desejáveis pela facilidade de interpretação, a busca por maior acurácia frequentemente exige estruturas mais complexas. Assim, o autor argumenta que a ênfase excessiva na simplicidade pode limitar o desempenho preditivo, defendendo que a precisão deve prevalecer sobre a interpretabilidade quando há conflito entre ambas.

O principal mecanismo teórico que anula essa dicotomia é o que Breiman (2001b) denominou de Efeito Rashomon. Conforme argumentado por Rudin (2025), esse efeito refere-se ao fato de que pode existir um conjunto de modelos com desempenhos estatisticamente equivalentes para resolver um mesmo problema de predição. Assim, a autora sustenta que a presença desse conjunto implica que, se houver muitas funções que se ajustam bem aos dados, é altamente provável que algumas delas sejam também interpretáveis. Essa perspectiva é fundamental para a área de AM explicável, pois indica que a busca por modelos compreensíveis não precisa necessariamente comprometer o desempenho, contrariando a ideia tradicional de que interpretabilidade e acurácia são objetivos opostos.

2.3 Aprendizado de máquina na predição de parto prematuro

O uso de AM revolucionou a pesquisa em saúde perinatal ao oferecer ferramentas capazes de realizar análises avançadas sobre os fatores de risco associados ao PP. Essas abordagens permitem discernir padrões complexos e identificar biomarcadores em grandes volumes

de instâncias, os quais seriam difíceis de detectar por métodos tradicionais baseados apenas em análise humana (Golob *et al.*, 2024; Park *et al.*, 2022).

Dessa maneira, modelos de AM demonstram uma capacidade significativamente maior de prever o PP em comparação com o uso isolado de variáveis clínicas ou microbianas (Kindschuh *et al.*, 2023). Assim, ele não se limita em classificar, mas também é capaz de ajudar na identificação de novos biomarcadores e na compreensão das interações biológicas (Fettweis *et al.*, 2019).

Com isso, surge a possibilidade de traduzir informações complexas em aplicações clínicas concretas. O uso de AM demonstra grande potencial para o desenvolvimento de testes diagnósticos precoces, não invasivos e de baixo custo, capazes de avaliar o risco de parto prematuro semanas ou meses antes do evento, fornecendo uma importante janela para intervenções clínicas (Chakoory *et al.*, 2024; Kindschuh *et al.*, 2023).

Além disso, essas abordagens permitem a identificação precisa de subpopulações de alto risco, o que pode facilitar a seleção de participantes para ensaios clínicos voltados a intervenções preditivas (Golob *et al.*, 2024). Assim, a identificação de assinaturas microbianas tem contribuído para a definição de um espectro generalizável do microbioma vaginal associado ao risco de parto prematuro, pavimentando o caminho para novas estratégias preventivas e terapêuticas personalizadas, tanto em nível populacional quanto individual (Chakoory *et al.*, 2024; Golob *et al.*, 2024; Park *et al.*, 2022).

2.3.1 Desafios de generalização e limitações

No contexto do AM e da modelagem preditiva, a generalização corresponde à habilidade de um modelo em preservar seu desempenho preditivo, como acurácia ou *Area Under the Curve* (AUC), quando avaliado em novos conjuntos de dados independentes ou não utilizados durante o processo de treinamento (Golob *et al.*, 2024). Esse aspecto é fundamental, pois garante que o modelo não esteja simplesmente memorizando o ruído ou as particularidades do conjunto de treinamento, mas sim capturando padrões biológicos capazes de se aplicar a diferentes indivíduos e contextos populacionais.

Contudo, alcançar uma boa generalização é um desafio quando as instâncias vêm de diferentes fontes e possuem muita variação. Como abordado, PP tem muitas causas possíveis e fatores diferentes envolvidos, o que torna pouco provável que todos os casos estejam ligados aos mesmos padrões do microbioma vaginal. Por isso, modelos que não consideram essas diferenças podem ter sua precisão reduzida, já que não conseguem representar bem todas as situações (Huang *et al.*, 2023).

A influência de fatores étnicos e raciais faz com que modelos preditivos e biomarcadores desenvolvidos a partir de populações pouco diversas não apresentem desempenho consistente quando aplicados a grupos com diferente composição genética e microbiana. Evidências mostram que o *Bacterial Vaginosis-Associated Bacterium 1* (BVAB1), por exemplo, é mais frequente em mulheres de ascendência africana e está associado ao PP, o que indica que certas ca-

racterísticas microbianas podem ocorrer de maneira desigual entre populações (Fettweis *et al.*, 2019). Esses achados reforçam que diferenças populacionais afetam tanto a estrutura do microbioma quanto o comportamento dos modelos, tornando essencial a inclusão de amostras diversas no desenvolvimento de algoritmos de AM voltados à saúde reprodutiva.

Também existem diferenças na capacidade de predição entre os casos de PP tardio (entre 34 e 37 semanas) e os precoces (antes de 32 ou 34 semanas), sendo que os casos mais precoces tendem a ser melhor previstos com base no perfil do microbioma vaginal (Huang *et al.*, 2023). Isso sugere que os partos extremamente prematuros estão mais frequentemente associados a processos inflamatórios e infecciosos, nos quais o desequilíbrio microbiano desempenha um papel mais direto e mensurável, enquanto nos casos tardios outros fatores fisiológicos e ambientais podem ter maior influência.

Outra questão relevante é a heterogeneidade metodológica e técnica entre diferentes pesquisas, especialmente no que diz respeito aos métodos de coleta e processamento das amostras. Segundo Huang *et al.* (2023), os estudos podem utilizar diferentes conjuntos de *primers* (pequenas sequências que iniciam a leitura do DNA durante o sequenciamento), e essa escolha pode afetar quais bactérias são detectadas com maior precisão. *Primers* que amplificam a região V1-V2 do gene 16S rRNA, por exemplo, tem menor eficiência na detecção de *Gardnerella* em comparação com os que atuam na região V4. Isso pode fazer com que a presença dessa bactéria seja subestimada ou até pareça ausente, introduzindo erros nos resultados e distorcendo as associações observadas entre microbioma e PP.

Portanto, considerando todas essas variações comuns entre estudos, como diferenças nas populações analisadas, nos métodos de coleta e nas abordagens laboratoriais, modelos de AM treinados em um conjunto de dados e testados em outro (avaliação cross-dataset) tendem a apresentar menor acurácia preditiva (Fettweis *et al.*, 2019; Golob *et al.*, 2024; Huang *et al.*, 2023). Isso ocorre porque a falta de padronização dificulta que o modelo reconheça padrões consistentes entre diferentes coortes, comprometendo sua capacidade de generalização (Gudnadottir *et al.*, 2022).

2.4 Medidas de avaliação e métodos de validação para biomarcadores microbianos e modelos de predição

Medidas de avaliação são utilizadas para quantificar o quanto um biomarcador ou um modelo de AM contribui para distinguir casos de PP ou PT. A confiabilidade de um biomarcador, frequentemente representado como uma variável preditora, pode ser avaliada estatisticamente por meio de métodos de modelagem, que buscam medir o quão bem o modelo pode prever resultados (predição) ou quão fidedignamente ele reflete os mecanismos subjacentes (informação) (Breiman, 2001b; Stiglic *et al.*, 2020).

A AUC ou AUROC é uma medida de avaliação amplamente utilizada e aceita para modelos de classificação binária, capaz de avaliar a capacidade geral do modelo de prever corretamente um desfecho em todas as classes (Huang *et al.*, 2023). Ademais, medidas de sensibili-

dade e especificidade são comumente utilizadas para avaliar o desempenho de biomarcadores ou modelos de classificação. A sensibilidade indica a capacidade do modelo de identificar corretamente os casos positivos (por exemplo, indivíduos com PP), enquanto a especificidade mede a habilidade de identificar corretamente os casos negativos (indivíduos com PT) (Fettweis *et al.*, 2019).

A acurácia também é frequentemente utilizada, representando a proporção de predições corretas em relação ao total de casos (Chakoory *et al.*, 2024). Para problemas com classes desequilibradas, como aqueles em que há muito mais partos a termo do que prematuros, medidas de avaliação como a *Area Under the Precision-Recall Curve* (AUPR) ou *Matthews Correlation Coefficient* (MCC) são particularmente importantes, possibilitando uma análise mais consistente do desempenho do modelo (Golob *et al.*, 2024; Kindschuh *et al.*, 2023; Park *et al.*, 2022).

Para confirmar se as associações microbianas são realmente significativas, é possível realizar a avaliação estatística de biomarcadores. Para isso, testes de diferença de abundância são utilizados para identificar táxons que estão diferencialmente presentes entre grupos, como o Teste U de Mann–Whitney (também chamado de *Wilcoxon Rank-Sum test*) (Fettweis *et al.*, 2019; Huang *et al.*, 2023). Esses testes são utilizados como etapa de validação dos biomarcadores, de modo que apenas aqueles cuja abundância apresentar diferenças estatisticamente significativas sejam considerados confiáveis.

Ademais, devido ao grande número de táxons testados simultaneamente em análises de microbioma, é fundamental ajustar o valor de p para controlar a taxa de falsas descobertas, evitando que resultados significativos ocorram apenas por acaso. Sem esse ajuste, a probabilidade de identificar associações incoerentes aumenta consideravelmente, especialmente em estudos que analisam centenas ou milhares de espécies ou variantes microbianas. A correção de Benjamini–Hochberg é um método amplamente utilizado para esse fim, produzindo um valor q que indica a significância ajustada, geralmente considerado relevante quando menor que 0,05 ou 0,1 (Fettweis *et al.*, 2019; Kindschuh *et al.*, 2023). Assim, é possível a identificação de biomarcadores microbianos que realmente diferenciam grupos clínicos.

Quanto à validação da generalização do modelo, que consiste na capacidade de manter o desempenho em novos dados, são aplicadas técnicas como validação cruzada (*cross-validation*), incluindo o método *k-fold*, que permite otimizar hiperparâmetros e estimar o desempenho interno, prevenindo o sobreajuste (Huang *et al.*, 2023). O sobreajuste (*overfitting*) ocorre quando o modelo memoriza padrões específicos dos dados de treinamento, incluindo ruído e particularidades, em vez de aprender padrões generalizáveis, podendo ser detectado pela diferença significativa entre o desempenho no conjunto de treinamento e na validação (Luo *et al.*, 2016). Para uma estimativa ainda mais robusta do erro de generalização, utiliza-se a validação cruzada aninhada, que separa estritamente os dados usados para ajuste de hiperparâmetros daqueles destinados à avaliação final, garantindo que o desempenho do modelo reflita sua capacidade de generalizar para coortes independentes (Kindschuh *et al.*, 2023).

No contexto de estudos com dados longitudinais, nos quais existem múltiplas amostras provenientes de um mesmo indivíduo, a técnica *GroupKFold* realiza a validação cruzada ao nível

de sujeito, garantindo que todas as amostras de uma mesma participante permaneçam em um único grupo (*fold*) durante a validação. Essa abordagem é necessária porque o *Stratified k-fold* tradicional não impede que amostras do mesmo indivíduo sejam distribuídas entre os conjuntos de treinamento e teste, o que pode inflar artificialmente o desempenho do modelo (Gao *et al.*, 2023).

Por fim, é crucial prevenir o chamado *data leakage* (vazamento de dados), que ocorre quando o conjunto de validação ou teste captura inadvertidamente informações do processo de treinamento, levando a uma superestimação do desempenho do modelo (Luo *et al.*, 2016). Para evitar isso, todas as etapas de pré-processamento e seleção de variáveis devem ser aplicadas separadamente dentro de cada partição da validação cruzada, garantindo que as estimativas de desempenho reflitam de fato a capacidade de generalização do modelo (Papoutsoglou *et al.*, 2023).

2.5 Trabalhos relacionados

Nesta seção, são apresentados estudos que exploram a relação entre o microbioma e a prematuridade sob diferentes perspectivas, organizados em ordem cronológica. O objetivo é oferecer uma visão abrangente do estado da arte, evidenciando como diferentes abordagens têm contribuído tanto para o desenvolvimento de modelos preditivos quanto para a compreensão dos mecanismos microbianos associados ao parto prematuro.

Entre os estudos analisados, a investigação conduzida por Fettweis *et al.* (2019) centrou-se na influência do microbioma vaginal no PP, destacando diferenças microbianas entre mulheres de ascendência africana e europeia. A análise utilizou dados do *Integrative Human Microbiome Project* (iHMP) – *Multi-Omic Microbiome Study: Pregnancy Initiative* (MOMS-PI), com 45 gestantes com PP espontâneo e 90 controles a termo, majoritariamente de ascendência africana e baixa renda. Para a construção do modelo preditivo, os dados de abundância microbiana foram previamente processados e normalizados, transformando-se os valores para o intervalo de 0 a 1, o que garantiu comparabilidade entre amostras e reduziu os efeitos de escalas. Ademais, foi realizada a seleção de quatro táxons discriminativos, *S. amnii*, BVAB1, *Prevotella* cluster 2 e *Bacterial Vaginosis-Associated Bacterium* TM7 (TM7-H1), por meio do teste U de Mann-Whitney, seguido da atribuição de pesos via regressão logística regularizada L1. O modelo resultante apresentou desempenho relevante, com AUROC de 0,723, sensibilidade de 77,4% e especificidade de 76,3%, corroborando a existência de diferentes estados do microbioma vaginal associados ao risco de PP, variando entre populações. Por fim, análises multi-ômicas confirmaram as assinaturas microbianas e sugerem que o microbioma no início da gestação tem maior potencial preditivo para PP, destacando a necessidade de validação em outras coortes.

Em uma coorte de 69 gestantes brasileiras, Freitas *et al.* (2020) examinaram a associação entre o microbioma vaginal e o risco de PP por meio do sequenciamento de 16S rRNA de amostras coletadas no momento do parto. O estudo teve como objetivo a identificação de poten-

ciais biomarcadores microbianos para o desfecho da gestação, comparando PT com casos de PP, tanto espontâneo quanto não espontâneo. Para isso, realizaram análises no *QIIME* e *DESeq2* para abundância diferencial, além de testes estatísticos (*PERMANOVA*, *Kruskal-Wallis*, *Wilcoxon*). Assim, os resultados mostraram que, embora a diversidade alfa não apresentasse diferenças significativas entre os grupos, a composição microbiana variava de forma marcante. Espécies do gênero *Lactobacillus* (como *L. iners* e *L. jensenii*) foram associadas ao PT, sugerindo um efeito protetor, enquanto espécies de *Prevotella* se mostraram mais abundantes no grupo de PP espontâneo, indicando possível papel como fator de risco.

Com o intuito de prever PP, a pesquisa de Park *et al.* (2022) integrou pela primeira vez o microbioma vaginal, Glóbulos Brancos (GL) e Comprimento Cervical (CC) por meio de técnicas de AM. Para isso, a análise microbiana foi feita utilizando sequenciamento de 16S rRNA em um estudo caso-controle com 150 gestantes coreanas (54 PP e 98 PT). Para a seleção de marcadores, sete métodos estatísticos (como *Wilcoxon*, *ANCOM*, *DESeq2* e *edgeR*) foram utilizados, resultando na identificação de espécies-chave como *Lactobacillus spp.*, *Gardnerella vaginalis*, *Ureaplasma parvum*, *Atopobium vaginae*, *Prevotella timonensis* e *Peptoniphilus grossensis*. Foram testados diferentes modelos de AM, e o FA obteve o melhor desempenho com AUC = 0,84 quando combinou microbioma, contagem de leucócitos e comprimento cervical. A regressão logística alcançou AUC = 0,72 e o *GUIDE*, embora com AUC = 0,77, destacou-se por fornecer melhor interpretação biológica, associando espécies como *U. parvum*, *P. timonensis* e *P. lacrimalis* ao risco de PP. Ademais, o grupo PP apresentou maior diversidade alfa, enquanto a beta permaneceu semelhante entre os grupos.

Aprofundando a análise do microbioma vaginal, Liao *et al.* (2023) avaliaram a microdiversidade genética durante a gestação, utilizando os dados do MOMS-PI previamente analisados por Fettweis *et al.* (2019), e comparou gestantes que tiveram parto prematuro espontâneo (PP espontâneo, n = 40) com aquelas de parto a termo (PT, n = 135). Os resultados indicaram que o microbioma associado ao PP apresentou maior diversidade de nucleotídeos em nível de espécie e maior potencial de resistência antimicrobiana, sendo o gênero *Gardnerella* um dos principais responsáveis por essa variabilidade, especialmente na primeira metade da gestação. Para alcançar essas conclusões, os autores analisaram 705 amostras vaginais por meio de metagenômica *shotgun*, reconstruíram *Metagenome-Assembled Genomes* (MAGs) de referência, aplicaram classificação taxonômica e utilizaram *Compositional Tensor Factorization* (CTF) para investigar a dinâmica temporal do microbioma ao longo da gestação.

Uma meta-análise abrangente de 12 coortes (2039 gestantes, das quais 586 apresentaram PP), realizada por Huang *et al.* (2023), empregou o sequenciamento do gene 16S rRNA para caracterizar o microbioma vaginal. Para avaliar o potencial preditivo em relação ao PP, foram aplicados modelos de FA em três cenários: *intra-dataset*, *cross-dataset* e *Leave-One-Dataset-Out* (LODO). A preditividade variou substancialmente entre os estudos com acurácia baixa a moderada (AUC 0,28-0,79), apresentando melhores resultados naqueles com coortes racialmente distintas e com melhor desempenho na previsão de PP antes das 34 semanas de gestação em comparação ao PP tardio. Ademais, a análise integrada de abundância diferencial

revelou uma associação negativa entre *Lactobacillus crispatus* e PP, enquanto a presença da maioria dos gêneros (18 de 25) esteve associada a maior risco. Nesse contexto, os autores empregaram a ferramenta SHAP para interpretar a contribuição de cada táxon na predição, evidenciando que *L. crispatus*, *Prevotella* e *L. iners* foram os microrganismos mais influentes nos modelos.

O potencial do metaboloma vaginal como biomarcador preditivo do PP espontâneo foi investigado por Kindschuh *et al.* (2023) ao analisar 232 amostras vaginais do segundo trimestre de gestação (dos quais 80 resultaram em PP espontâneo). Para o desenvolvimento dos modelos preditivos, foram avaliados três tipos de instâncias de entrada: covariáveis clínicas maternas (idade, Índice de Massa Corporal (IMC), raça, histórico de parto prematuro e nuliparidade), microbioma vaginal (sequenciamento 16S rRNA) e metaboloma vaginal (níveis de metabólitos obtidos por espectrometria de massas). O modelo de predição foi desenvolvido com o algoritmo de *boosted decision trees*, no qual o microbioma apresentou desempenho limitado (AUROC = 0,55), enquanto o metaboloma obteve maior robustez (AUROC = 0,78), superando inclusive o modelo combinado (AUROC = 0,76). Ademais, foram observadas diferenças significativas entre os metabolomas de mulheres de diferentes raças, com forte associação entre o metaboloma vaginal e PP espontâneo em mulheres negras. No geral, os resultados indicam que o metaboloma vaginal constitui um biomarcador precoce, mais sensível que o microbioma.

Golob *et al.* (2024) destacam que o PP está associado a maiores taxas de mortalidade neonatal e complicações a longo prazo para os indivíduos. Assim, a capacidade de implementação de estratégias que possibilitem a identificação precisa de gestações de risco é essencial para prevenir e contornar essas situações. Para isso, os autores organizaram o *Microbiome Pre-term Birth DREAM Challenge*, lançado em 2019, utilizando *crowdsourcing* e dados longitudinais do microbioma para prever PP (<37 semanas) e o PP extremo a muito prematuro (<32 semanas). Com instâncias de nove coortes, totalizando 3.758 amostras de 1.268 gestantes, além de conjuntos independentes disponibilizados para validação, os melhores modelos alcançaram AUROC de até 0.87, destacando diversidade alfa, *Community State Types* (CST) e composição microbiana como variáveis relevantes para a predição. Dessa maneira, o estudo fornece uma base sólida para a investigação de novos mecanismos e biomarcadores relacionados à PP, embora avance principalmente na capacidade preditiva, sem elucidar os mecanismos interpretativos.

O estudo de Chakoory *et al.* (2024) analisou cinco coortes independentes, com um total de 1290 amostras vaginais de 561 gestantes, das quais 1029 tiveram PT e 261 PP. Para isso, foi desenvolvido o modelo DeepMPP, baseado em *Deep Neural Network* (DNN), para prever risco de PP, alcançando acurácia de 84,10% e AUROC de 0,875, superando sete algoritmos de referência, incluindo AD, *K-Nearest Neighbor* (KNN), FA, *Naïve Bayes* (NB), XGBoost, Regressão Logística (RL) e *Support Vector Machine* (SVM). A análise de interpretabilidade foi feita com SHAP e identificou as 20 características mais relevantes para o desempenho do modelo, revelando que espécies de baixa abundância tiveram impacto na classificação. Por fim, um achado central foi que a diversidade global da microbiota vaginal mostrou-se mais robusta para prever

o PP do que a presença de espécies individuais, indicando que o risco estaria mais associado a padrões comunitários amplos e não a microrganismos isolados.

A partir da integração de um quadro conjunto de dados públicos de sequenciamento de 16S rRNA com 337 amostras, a pesquisa de Li *et al.* (2024) buscou investigar assinaturas microbianas associadas ao PP. Com base em *Operational Taxonomic Units* (OTUs), foram construídos modelos de classificação FA utilizando validação cruzada estratificada de 10 vezes. Assim, o modelo alcançou AUC de 0,88, sendo posteriormente validado por transferência entre estudos, validação LODO e em coortes independentes com instâncias de metagenoma shotgun e *Whole Genome Sequencing* (WGS) coletados em laboratório. Os autores identificaram 20 gêneros diferenciais, incluindo *Lactobacillus*, *Prevotella*, *Gardnerella* e *Atopobium*, que se destacaram como biomarcadores robustos para distinção entre gestações PT e PP, evidenciando o potencial de abordagens de AM na estratificação de risco para a prematuridade.

Explorando a interface entre nutrição e microbioma, Napolini *et al.* (2025) investigaram a relação entre a amamentação exclusiva e a maturação do microbioma intestinal de lactentes, considerando o modo de parto. Para isso, foram utilizadas 525 amostras fecais da coorte Germina, coletadas entre 3 e 9 meses de idade, e analisadas por sequenciamento metagenômico total. Foram aplicados modelos de FA para prever a prática de amamentação exclusiva com base em espécies microbianas e vias metabólicas, além de empregar valores SHAP a fim de interpretar a contribuição de cada variável para as predições dos modelos. Para assegurar a robustez estatística das interpretações, os autores realizaram um teste de permutação com 10.000 iterações, calculando um valor-p empírico para avaliar se o modelo prevê a prática de amamentação exclusiva melhor do que o acaso, confirmando que as importâncias atribuídas às variáveis são significativas. Ademais, a validação por *Leave-One-Out Cross-Validation* (LOOCV) assegurou a generalização dos resultados mesmo em subgrupos de tamanho limitado (57 a 361 amostras), reforçando a confiabilidade do modelo e de suas interpretações para aplicações em cenários clínicos realistas.

De forma geral, os estudos apresentados no Quadro 1 revelam uma trajetória metodológica que vai de análises estatísticas clássicas (Freitas *et al.*, 2020) e primeiros modelos preditivos baseados em regressão (Fettweis *et al.*, 2019) até abordagens multi-ômicas e de aprendizado supervisionado mais complexas (Park *et al.*, 2022; Kindschuh *et al.*, 2023), culminando em meta-análises e arquiteturas profundas que ampliam a capacidade preditiva e a generalização intercoorte (Huang *et al.*, 2023; Golob *et al.*, 2024; Li *et al.*, 2024; Chakoory *et al.*, 2024). Apesar das diferenças entre populações, técnicas e desfechos, destacam-se achados recorrentes, como a redução de *L. crispatus* e o aumento de *Gardnerella* e, frequentemente, de *L. iners*. Destaca-se Chakoory *et al.* (2024) pelo uso de uma DNN, cuja interpretabilidade via SHAP permitiu identificar robustamente os microrganismos mais relevantes, enquanto Napolini *et al.* (2025) evidencia a aplicabilidade dessas abordagens de AM em outro contexto, o do microbioma infantil.

Esses trabalhos não apenas consolidam evidências sobre biomarcadores microbianos maternos, mas também oferecem fundamentos metodológicos e conceituais essenciais para o

desenvolvimento e validação de modelos preditivos neste trabalho, reforçando a importância de integrar análise estatística rigorosa e interpretação biológica na pesquisa de prematuridade.

Quadro 1 – Comparação de resultados dos trabalhos relacionados

Estudo	Conjunto de Dados	Técnicas / Modelos	Melhor Resultado	Biomarcadores Identificados
Fettweis <i>et al.</i> (2019)	iHMP–MOMS-PI (45 PP espontâneo, 90 PT) (78% Afr.)	Mann-Whitney; regularização L1 (L1)	AUROC = 0,723 (+5–7% vs. clínico)	↑ <i>Sneathia amnii</i> ; ↑ BVAB1; ↑ <i>Prevotella cluster 2</i> ; ↑ TM7-H1; ↓ <i>Lactobacillus crispatus</i>
Freitas <i>et al.</i> (2020)	Coorte brasileira (23 PP espontâneo, 29 PT)	DESeq2; SparCC	DESeq2 (p-ajustado ≤ 0.05)	↑ <i>L. iners</i> (PT); ↑ <i>Prevotella</i> sp. (PP espontâneo)
Park <i>et al.</i> (2022)	Coorte coreana (54 PP, 96 PT) + GL + CC	FA, RL, XGBoost	FA: AUC = 0,84	↓ <i>L. crispatus</i> ; ↑ <i>P. lacrimalis</i> ; ↑ <i>U. urealyticum</i>
Liao <i>et al.</i> (2023)	MOMS-PI (40 PP espontâneo, 135 PT)	Shotgun; MAGs; CTF	S1 (0–19 sem) vs S2 (20–37 sem); RAM (subamostragem 10^5 , CARD)	↑ Microdiversidade; ↑ Genes de RAM; <i>Gardnerella</i> spp.
Huang <i>et al.</i> (2023)	Meta-análise (12 coortes; 586 PP)	FA + SHAP; LODO	AUC = 0,56–0,62 (Melhor em PP < 34 sem)	↓ <i>L. crispatus</i> ; ↑ <i>L. iners</i> , <i>Gardnerella</i>
Kindschuh <i>et al.</i> (2023)	232 amostras (80 PP espontâneo, 152 PT)	LightGBM; Metabolômica	Metaboloma: AUROC = 0,78	↑ DEA; ↓ Colina; (Mais forte em negras)
Golob <i>et al.</i> (2024)	Meta-análise (9 coortes; 1268 gest.)	Crowdsourcing (AM); <i>Ensemble</i> (Top models)	PP <37s: AUROC = 0,74 PP <32s: AUROC = 0,91	↑ Diversidade alfa; ↑ CST não- <i>Lactobacillus</i> ; ↓ <i>L. crispatus</i> ; ↑ <i>G. vaginalis</i>
Chakoory <i>et al.</i> (2024)	5 coortes (261 PP) + Validação	DNN (DeepMPPT)	AUROC = 0,875	Foco na interação global. SHAP: ↑ <i>G. vaginalis</i> ; ↑ <i>L. iners</i> ; ↓ <i>L. crispatus</i> ; + Dados clínicos
Li <i>et al.</i> (2024)	Meta-análise (4 coortes 16S; 181 PP)	FA; LODO; Val. multi-coorte (16S); Val. externa (WGS)	AUC = 0,88 (16S); 0,73–0,64 (WGS)	↓ <i>Lactobacillus</i> ; ↑ <i>Gardnerella</i> ; ↑ <i>Prevotella</i>
Naspolini <i>et al.</i> (2025)	Corte prospectiva (525 lactentes)	Metagenômica total; FA + SHAP; LO-OCV	Acurácia balanceada: 0,57–0,74 (espécies); 0,61–0,64 (vias)	Microbioma infantil, não associado à PP

Fonte: Autoria própria (2026).

3 MATERIAIS E MÉTODOS

O presente capítulo descreve os materiais e metodologias adotados para a execução deste trabalho, desde a caracterização do conjunto de dados utilizado até as etapas de processamento, modelagem e análise. Inicialmente, são apresentados os recursos empregados, incluindo a base de dados do *Microbiome Preterm Birth DREAM Challenge* e a infraestrutura computacional utilizada para a condução dos experimentos. Em seguida, é descrita a metodologia aplicada, contemplando as etapas de pré-processamento, construção e avaliação dos modelos preditivos, bem como os procedimentos para a identificação e validação estatística dos biomarcadores microbianos.

3.1 Materiais

Esta seção apresenta os materiais utilizados no desenvolvimento deste trabalho, incluindo a descrição do conjunto de dados empregado, suas principais variáveis e a infraestrutura computacional adotada para a execução dos experimentos.

3.1.1 Conjunto de dados

Este trabalho utilizou o conjunto de dados públicos do *Microbiome Preterm Birth DREAM Challenge*¹, uma iniciativa de *crowdsourcing* coordenada por Golob *et al.* (2024), voltada à predição do PP a partir de dados do microbioma vaginal por meio de técnicas de aprendizado de máquina.

A base de dados de treinamento foi construída a partir da agregação e harmonização de nove estudos longitudinais independentes, cujos dados brutos estavam disponíveis em repositórios públicos, como o *dbGAP* e o *March of Dimes (MOD) Database for Preterm Birth Research*. A consolidação dos dados resultou em um conjunto de 3.578 amostras vaginais provenientes de 1.268 gestantes. Entre essas participantes, 851 tiveram PT (≥ 37 semanas de gestação) e 417 tiveram PP (< 37 semanas), incluindo 170 casos de PP precoce (< 32 semanas). Ademais, para garantir relevância clínica e reduzir vieses, foram aplicados critérios de inclusão baseados na idade gestacional no momento da coleta. Portanto, apenas amostras obtidas entre as semanas 10 e 30 de gestação foram mantidas no conjunto de dados de treinamento.

Cada estudo incluído utilizou protocolos distintos de sequenciamento do gene 16S rRNA, com diferentes regiões variáveis e plataformas de sequenciamento. Para possibilitar a integração dos dados, foi aplicado o fluxo de trabalho MaLiAmPi (*Microbiome Alignment and Integration via Phylogenetic Placement*), que harmoniza as sequências por meio de posicionamento filogenético em uma árvore de máxima verossimilhança, resultando em um conjunto coerente de atributos composicionais.

¹ *ImmPort Dataset 38134931*

Para permitir a comparação justa e avaliar a capacidade de generalização dos modelos, o *DREAM Challenge* disponibilizou também dois conjuntos independentes de validação para testar a generalização dos modelos. O primeiro foi proveniente da Wayne State University (159 amostras de 60 gestantes), e o segundo foi gerado pela University of California, San Francisco (UCSF), com 172 amostras de 88 gestantes. Dessa forma, o presente trabalho utilizou o conjunto de treinamento informado, além de dois conjuntos independentes destinados aos testes, ambos disponibilizados para avaliar a capacidade de generalização dos modelos.

As variáveis fornecidas aos participantes do desafio e utilizadas neste trabalho foram processadas em múltiplos níveis de abstração biológica e taxonômica, incluindo:

- **Tabelas taxonômicas:** Matrizes de abundância de sequências agregadas em diferentes níveis taxonômicos (*espécie*, *gênero* e *família*), derivadas do sequenciamento do gene 16S rRNA. Permitem caracterizar a composição microbiana e identificar organismos dominantes ou raros nas amostras.
- **Filotipos:** Agrupamentos de sequências baseados em similaridade filogenética, definidos por limiares de distância de 1%, 0,5% e 0,1%. Essa representação independe da taxonomia tradicional e captura variações genéticas sutis entre microrganismos, ampliando a resolução biológica e a robustez dos modelos preditivos.
- **Diversidade alfa:** Métricas de riqueza e uniformidade microbiana em cada amostra, calculadas por índices como *Shannon*, *Simpson* e *Chao1*. Fornecem uma visão ecológica da estabilidade e complexidade do microbioma vaginal.
- **CST:** Classificam as amostras segundo o classificador *VALENCIA*, que agrupa o microbioma vaginal em perfis ecológicos dominados por diferentes espécies do gênero *Lactobacillus* ou por comunidades mistas mais diversas:
 - **CST I:** Dominado por *Lactobacillus crispatus*;
 - **CST II:** Dominado por *Lactobacillus gasseri*;
 - **CST III:** Dominado por *Lactobacillus iners*;
 - **CST IV:** Comunidade heterogênea, com menor presença de *Lactobacillus* e maior diversidade microbiana;
 - **CST V:** Dominado por *Lactobacillus jensenii*.

3.1.2 Ambiente computacional

As análises e experimentos deste estudo foram realizados no ambiente Google Colaboratory (Colab)², uma plataforma em nuvem gratuita disponibilizada pelo Google que fornece um ambiente interativo de notebooks Jupyter, dispensando configurações locais de hardware ou software (Bisong, 2019). Essa ferramenta permite a execução de código em linguagem Python diretamente em servidores remotos, com acesso a recursos computacionais de alto desempenho, incluindo unidades de processamento gráfico (GPU) e unidades de processamento de tensores (TPU), o que a torna adequada para tarefas de aprendizado de máquina e modelagem de dados em larga escala. Assim, por oferecer infraestrutura acessível e compatível com bibliotecas amplamente utilizadas em ciência de dados, o Colab representa uma solução prática e economicamente viável para o desenvolvimento e a prototipagem de modelos preditivos, especialmente em estudos que demandam processamento intensivo, mas não envolvem dados sensíveis ou restrições de privacidade.

Durante o desenvolvimento deste trabalho, o Colab operava com Python 3.12, oferecendo suporte integrado às bibliotecas mais utilizadas em ciência de dados e aprendizado de máquina, como NumPy 2.0.2, pandas 2.2.2, scikit-learn 1.6.0, SciPy 1.16.1, TensorFlow 2.19.0 e PyTorch 2.8.0, além de pacotes para visualização (matplotlib 3.10.0, seaborn 0.13.2) e interpretabilidade de modelos (SHAP 0.48.0)³. As principais bibliotecas utilizadas no ambiente Colab foram selecionadas de acordo com sua relevância para o fluxo de análise de dados e aprendizado de máquina, seguindo Bisong (2019), Grus (2016). Entre elas:

- **NumPy**⁴: Biblioteca Python otimizada para computação numérica, considerada o principal pacote para esse tipo de processamento. Permite criar e manipular *arrays* n-dimensionais, incluindo vetores e matrizes, essenciais para aprendizado de máquina;
- **pandas**⁵: Biblioteca para análise e manipulação de dados estruturados, com destaque para suas estruturas *Series* (vetores unidimensionais) e *DataFrame* (tabelas bidimensionais). Facilita a limpeza, transformação e exploração de dados, além de oferecer funcionalidades para lidar com dados ausentes e séries temporais;
- **scikit-learn**⁶: Biblioteca para aprendizado de máquina com interface padronizada. Inclui ferramentas de pré-processamento, seleção e avaliação de modelos, otimização de hiperparâmetros e implementações eficientes de algoritmos clássicos de classificação, regressão e agrupamento;

² <https://colab.google/>

³ <https://colab.research.google.com/notebooks/relnotes.ipynb>

⁴ <https://numpy.org/>

⁵ <https://pandas.pydata.org/>

⁶ <https://scikit-learn.org/stable/>

- **SciPy**⁷: Pacote para cálculos científicos e estatísticos que complementa o *NumPy*. Oferece funções avançadas para integração, otimização, álgebra linear, interpolação, análise de sinais e estatística, sendo amplamente utilizado em pesquisas científicas, bioinformática e microbioma;
- **matplotlib**⁸ e **seaborn**⁹: Bibliotecas de visualização de dados. O *matplotlib* oferece gráficos personalizáveis e comandos similares ao MATLAB, enquanto o *seaborn* fornece uma interface de alto nível para visualizações estatísticas mais sofisticadas, com integração ao *pandas*;
- **SHAP**¹⁰: Biblioteca para explicabilidade *post hoc* de modelos preditivos utilizada para estimar quanto cada atributo contribui para a previsão realizada pelo modelo em uma instância específica. Portanto, gera explicações aditivas, em que a soma das contribuições das variáveis corresponde ao valor previsto pelo modelo para aquele exemplo.

3.2 Metodologia

A metodologia adotada neste trabalho foi estruturada para permitir uma análise detalhada do microbioma vaginal e a predição do desfecho do parto. O fluxo geral do estudo está apresentado nas Figuras 1 e 2, que sintetizam, respectivamente, o fluxo de preparação dos dados, modelagem e avaliação dos modelos preditivos, e o fluxo de identificação, comparação e consolidação dos biomarcadores microbianos derivados desses modelos. Portanto, essa organização permite visualizar todas as etapas do processo metodológico que garante que os biomarcadores identificados sejam avaliados quanto à sua confiabilidade, possibilitando investigar se diferenças significativas justificam o uso de modelos opacos em comparação com modelos transparentes.


⁷ <https://scipy.org/>

⁸ <https://matplotlib.org/>

⁹ <https://seaborn.pydata.org/>


¹⁰ <https://shap.readthedocs.io/>

Figura 1 – Fluxo de preparação, modelagem e avaliação dos modelos preditivos.



Fonte: Autoria Própria (2025).

Figura 2 – Fluxo de identificação, comparação e consolidação de biomarcadores microbianos.



Fonte: Autoria Própria (2025).

3.2.1 Pré-processamento

A etapa de pré-processamento teve início com a filtragem das amostras, removendo aquelas com baixa cobertura de sequências ou metadados incompletos, a fim de garantir a consistência e a qualidade do conjunto de dados. Em seguida, foi realizada a filtragem de táxons raros, excluindo táxons com baixa prevalência (presentes em poucas amostras ou com abundância média inferior a um limite mínimo definido), de modo a reduzir o ruído e evitar que microrganismos pouco expressivos interfiram na modelagem. Diversos critérios de filtragem são propostos na literatura. Fettweis *et al.* (2019) mantêm táxons cuja abundância seja de pelo menos 1% em 5% das amostras ou de pelo menos 0,1% em 15% das amostras. Huang *et al.* (2023) adotam um critério duplo, retraindo espécies com abundância média superior a 0,1% e prevalência acima de 10%. Park *et al.* (2022) exigem frequência mínima de 25% e proporção média de pelo menos 0,001%, enquanto Freitas *et al.* (2020) removem táxons não observados em pelo menos 20% das amostras. A escolha do critério adequado depende das características do conjunto de dados e do equilíbrio entre reduzir a esparsidade e preservar biomarcadores biologicamente relevantes.

Os dados de abundância relativa do microbioma são composicionais, ou seja, representam proporções que somam um total fixo (100%). Essa característica cria dependências artificiais entre as variáveis, onde, se a abundância de uma espécie aumenta em termos relativos, as demais necessariamente diminuem, mesmo que suas abundâncias absolutas não tenham se alterado. Para resolver esse problema, as abundâncias foram transformadas por meio da *Centered Log-Ratio* (CLR), que remove o efeito de soma constante e produz valores adequados para análises estatísticas e de aprendizado de máquina (Papoutsoglou *et al.*, 2023). Antes da aplicação da transformação, foi adicionada uma pseudocontagem mínima às abundâncias relativas, uma vez que o logaritmo de zero é matematicamente indefinido e a presença de valores nulos é frequente em dados de microbioma devido à alta esparsidade.

Após a transformação, foi aplicada a padronização das variáveis, com média zero e desvio padrão igual a um (*z-score*), de modo a equilibrar as escalas das abundâncias e garantir que nenhuma variável domine o processo de otimização dos modelos. Também foi conduzida uma análise exploratória de qualidade, por meio de técnicas de visualização como gráficos de dispersão e medidas de variância, com o intuito de verificar a adequação das transformações e a ausência de viés entre estudos.

Ademais, sempre que possível, variáveis clínicas e demográficas, como a idade gestacional no momento da coleta, foram incluídas como covariáveis nos modelos, a fim de reduzir potenciais efeitos de confusão e assegurar maior validade biológica às análises. Variáveis categóricas, como o tipo de comunidade microbiana (CST), foram convertidas em variáveis binárias por meio de *one-hot encoding*, técnica que cria uma coluna para cada categoria contendo valores 0 ou 1, uma vez que os algoritmos de aprendizado de máquina utilizados neste trabalho requerem entradas numéricas.

Tendo em vista a disparidade no número de instâncias entre as classes, foi avaliado o uso da ponderação de classes (*class_weight='balanced'*). Esse mecanismo atribui maior peso à classe minoritária (parto prematuro) durante o treinamento, corrigindo o desbalanceamento sem a necessidade de gerar dados artificiais. Os modelos foram avaliados com e sem essa ponderação para verificar seu impacto efetivo no desempenho.

3.2.2 Modelagem

O objetivo da etapa de modelagem foi avaliar o desempenho de algoritmos com diferentes níveis de interpretabilidade na tarefa de predição do desfecho do parto (termo ou pré-termo), a partir das abundâncias relativas do microbioma vaginal.

Utilizaram-se dois algoritmos supervisionados de classificação, um modelo opaco e outro transparente. O uso de algoritmos supervisionados justifica-se pelo objetivo central deste trabalho, que consiste em prever o desfecho do parto a partir de amostras de microbioma vaginal cujos rótulos já são conhecidos. Dessa forma, é possível construir um classificador capaz de generalizar esse conhecimento e prever corretamente o desfecho de novas amostras não vistas durante o treinamento.

Além disso, a adoção de algoritmos supervisionados permite avaliar não apenas a capacidade preditiva dos modelos, mas também a contribuição individual de cada microrganismo para a decisão de classificação, o que é essencial para a identificação de possíveis biomarcadores associados ao parto prematuro. Portanto, foram utilizados dois classificadores principais, a árvore de decisão, que representa um modelo inerentemente interpretável, e a floresta aleatória, que representa um modelo opaco, cuja interpretabilidade foi obtida por meio de métodos *post-hoc*, neste caso o SHAP.

Como apresentado anteriormente, devido à existência de um conjunto de dados independente destinado à etapa de testes, não será necessária a divisão do conjunto de treinamento para esse fim. Assim, o conjunto de treino foi utilizado integralmente para o ajuste e validação interna dos modelos. Para o controle de sobreajuste e avaliação da robustez do desempenho, foram adotadas duas estratégias de validação cruzada. A *stratified k-fold* garante a manutenção da proporção das classes em cada divisão, enquanto a *GroupKFold* agrupa as amostras por participante em cenários com múltiplas amostras por indivíduo, conforme descrito na Seção 2.4.

Para o ajuste dos hiperparâmetros, foi empregada a busca exaustiva por meio do *Grid-SearchCV*, que avalia todas as combinações possíveis de hiperparâmetros e seleciona a melhor com base no desempenho obtido via validação cruzada interna. Ao final da busca, o modelo é automaticamente retreinado com todos os dados de treinamento utilizando a combinação de hiperparâmetros que apresentou o melhor desempenho. Na árvore de decisão, foram otimizados parâmetros como o critério de divisão, a profundidade máxima, o número mínimo de amostras por folha e por divisão, e a ponderação de classes. Na floresta aleatória, a profundidade máxima foi fixada sem limite, conforme a formulação original de Breiman (2001a), e os demais parâme-

tros foram otimizados, incluindo o número de estimadores, o mínimo de amostras por folha e por divisão, a fração de atributos considerados em cada divisão e a ponderação de classes.

Para garantir a reprodutibilidade dos experimentos, todos os procedimentos de treinamento e validação utilizaram *random seeds* fixos, assegurando que os resultados possam ser replicados em execuções subsequentes. Adotaram-se versões específicas das bibliotecas Python mencionadas, e os experimentos foram realizados na plataforma Colab, proporcionando um ambiente padronizado e controlado para o desenvolvimento e teste dos modelos.

3.2.3 Avaliação

Para avaliar o desempenho dos modelos de classificação, inicialmente considera-se a matriz de confusão, que resume as previsões do modelo em relação aos rótulos reais. A matriz permite identificar a quantidade de:

- **Verdadeiros Positivos (TP)**: Casos positivos corretamente classificados;
- **Verdadeiros Negativos (TN)**: Casos negativos corretamente classificados;
- **Falsos Positivos (FP)**: Casos negativos incorretamente classificados como positivos;
- **Falsos Negativos (FN)**: Casos positivos incorretamente classificados como negativos.

A partir da matriz de confusão, é possível calcular diversas métricas de desempenho. Neste trabalho, foram consideradas as seguintes:

- **Acurácia**: Proporção de previsões corretas em relação ao total de amostras;

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

- **Precisão**: Proporção de acertos entre as amostras preditas como positivas;

$$\text{Precisão} = \frac{TP}{TP + FP} \quad (2)$$

- **Recall (Sensibilidade)**: Proporção de amostras positivas corretamente identificadas;

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3)$$

- **F1-Score**: Média harmônica entre precisão e *recall*, balanceando ambos os aspectos;

$$F1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}} \quad (4)$$

- **MCC:** Avaliação da qualidade da classificação considerando todos os elementos da matriz de confusão;

$$MCC = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (5)$$

Ademais, foram consideradas também medidas que avaliam o desempenho do modelo ao longo de diferentes limiares de decisão, especialmente úteis em cenários com classes desbalanceadas:

- **AUROC:** Mede a capacidade do modelo de discriminar entre as classes positiva e negativa ao longo de diferentes limiares de decisão.
- **AUPR:** Avalia a capacidade do modelo de identificar corretamente as amostras positivas considerando simultaneamente precisão e *recall*.

3.2.4 Identificação e comparação de biomarcadores

Para identificar biomarcadores microbianos que diferenciam grupos clínicos, foram aplicadas técnicas de avaliação da importância de atributos obtidas a partir dos modelos de classificação, incluindo medidas derivadas de árvore de decisão e floresta aleatória.

Em cada árvore individual, a importância de um atributo foi analisada com base na redução da impureza ou ganho de informação (*information gain*), que indica quanto a divisão do conjunto de dados por aquele atributo contribui para separar corretamente as classes. A impureza foi calculada utilizando índices como Gini ou entropia, que quantificam a homogeneidade das classes em cada nó da árvore. Na floresta aleatória, a importância final de um atributo foi obtida pela média das reduções de impureza ao longo de todas as árvores, fornecendo um ranqueamento global dos microrganismos mais relevantes para a predição do desfecho do parto.

Além disso, foi aplicada a técnica *post-hoc* SHAP, que permite avaliar a contribuição de cada atributo em cada predição individual, possibilitando identificar não apenas quais microrganismos são mais relevantes, mas também como eles influenciam o resultado do modelo.

3.2.5 Análise de incerteza e confiabilidade estatística

Para confirmar se os biomarcadores identificados realmente diferenciam os grupos clínicos, foram realizados testes de diferença de abundância, como Mann–Whitney ou Wilcoxon. Dessa forma, apenas os microrganismos cuja abundância apresentar diferenças estatisticamente significativas entre os grupos foram considerados biomarcadores confiáveis. Para cada atributo, foi calculado o *p-value* a partir desses testes, permitindo avaliar a significância estatística das associações identificadas. Os valores de *p* menores que o limiar que foi estabelecido foram considerados indicativos de diferenças estatisticamente significativas, reforçando a confi-

abilidade do biomarcador. Dessa maneira, o *p-value* funcionou como uma métrica quantitativa para selecionar os microrganismos cuja variação entre grupos é consistente e significativa.

Além disso, foi realizada uma comparação dos biomarcadores identificados pelos dois modelos utilizados, a árvore de decisão (transparente) e a floresta aleatória (opaca), com o objetivo de avaliar como diferentes níveis de interpretabilidade impactaram a seleção de microrganismos relevantes. Essa comparação permitiu verificar se os modelos opacos, apesar de supostamente apresentarem maior capacidade preditiva, ofereceram informações consistentes sobre os biomarcadores, ou se os modelos transparentes forneceram resultados mais confiáveis e interpretáveis. Dessa maneira, foi possível discutir não apenas a consistência estatística, mas também a utilidade prática e a confiabilidade das descobertas em diferentes abordagens de modelagem.

4 RESULTADOS E DISCUSSÃO

Este capítulo apresenta e discute os resultados obtidos a partir da metodologia descrita no Capítulo 3. Inicialmente, são reportados os resultados, abrangendo a caracterização do conjunto de dados após o pré-processamento, o desempenho preditivo dos modelos interpretável e opaco, os biomarcadores microbianos identificados em cada abordagem, a comparação entre os ranqueamentos obtidos e a avaliação de sua confiabilidade estatística. Em seguida, os achados são discutidos à luz da literatura, com ênfase na relação entre interpretabilidade e capacidade preditiva, na consistência dos biomarcadores e nas implicações para a adoção responsável de AM em contextos clínicos.

4.1 Resultados

Esta seção apresenta os principais resultados obtidos neste trabalho. Inicialmente, são descritas as características do conjunto de dados e os efeitos das etapas de pré-processamento. Em seguida, são apresentados os desempenhos dos modelos avaliados, os biomarcadores identificados e a comparação entre as diferentes abordagens de interpretação.

4.1.1 Caracterização e pré-processamento do conjunto de dados

O conjunto de dados do DREAM Challenge, após carregamento e exploração, revelou 1.895 amostras provenientes de 616 gestantes distribuídas em 8 coortes. A tabela de taxonomia por abundância relativa continha 2.118 espécies, com esparsidade de 97,4%, ou seja, a grande maioria dos valores na matriz de abundância era zero. Das 616 gestantes, 349 (56,7%) tiveram parto a termo e 267 (43,3%) tiveram parto prematuro. A distribuição racial mostrou predominância de mulheres de ascendência africana (43,3%) e europeia (37,8%), com representação menor de asiáticas (12,7%) e demais grupos.

O caráter longitudinal do estudo introduziu um desafio metodológico relevante, uma vez que cada gestante possuía entre 1 e 22 amostras coletadas em diferentes semanas gestacionais, com mediana de 2 amostras por participante. Essa variabilidade temporal exigiu a definição de uma estratégia de representação individual para utilização nos modelos preditivos. Assim, foram comparadas empiricamente quatro abordagens distintas: (A) seleção da amostra mais precoce de cada gestante, estratégia frequentemente empregada em estudos voltados à predição precoce do parto prematuro (Fettweis *et al.*, 2019; Gudnadottir *et al.*, 2022); (B) utilização da mediana das abundâncias microbianas por gestante, conforme proposto por Liao *et al.* (2023); (C) cálculo da média das abundâncias relativas entre as amostras disponíveis, abordagem semelhante à utilizada por Hyman *et al.* (2014); e (D) manutenção de todas as amostras sem agregação prévia, conforme Golob *et al.* (2024).

A comparação entre as estratégias produziu resultados informativos. Para espécies dominantes como *Lactobacillus crispatus* e *L. iners*, as diferenças entre abordagens foram míni-

mas, com variação inferior a 2,2%. Contudo, para patógenos associados ao parto prematuro as diferenças foram expressivas. *Gardnerella vaginalis* apresentou abundância 32% menor na mediana e 16,3% menor na média em relação à amostra precoce, enquanto *Sneathia amnii* apresentou redução de 18,8% na mediana e 4,3% na média. Esses achados são coerentes com Liao *et al.* (2023), que demonstraram que *Gardnerella* apresenta maior diversidade genética na primeira metade da gestação, e com Fettweis *et al.* (2019), que observaram que táxons associados ao parto prematuro tendem a diminuir em abundância ao longo da gravidez.

A utilização de todas as amostras sem agregação evidenciou ainda um potencial viés amostral, uma vez que gestantes com parto a termo apresentaram, em média, maior número de coletas (3,5) em comparação às gestantes com parto prematuro (2,5). Como consequência, a proporção de casos de parto prematuro no conjunto de dados foi reduzida de 43,3% para 35,5%, indicando super-representação das gestantes com maior número de observações longitudinais. Considerando esses resultados, optou-se por adotar prioritariamente a representação baseada na amostra mais precoce, mantendo adicionalmente a análise sem agregação para fins comparativos.

As duas estratégias selecionadas para os experimentos subsequentes são sintetizadas no Quadro 2, que apresenta suas respectivas descrições e referências na literatura. A primeira prioriza a relevância biológica da coleta precoce, enquanto a segunda maximiza o volume de dados disponível para o treinamento, adotando validação cruzada agrupada por participante para mitigar o risco de *data leakage*.

Quadro 2 – Estratégias de agregação temporal das amostras avaliadas

Estratégia	Descrição	Referência
Amostra precoce	Coleta mais precoce de cada gestante	Fettweis <i>et al.</i> (2019); Gudnadottir <i>et al.</i> (2022)
Todas as amostras	Todas as coletas, com validação agrupada por participante (GroupKFold)	Golob <i>et al.</i> (2024); Huang <i>et al.</i> (2023)

Fonte: Autoria própria (2026).

Para a filtragem de táxons raros, foram comparados os critérios descritos na metodologia com base no número de espécies retidas e na preservação de biomarcadores associados ao parto prematuro. Na abordagem baseada na amostra mais precoce, o critério proposto por Fettweis *et al.* (2019) manteve 21 espécies, o de Huang *et al.* (2023) preservou 43, o de Park *et al.* (2022) reteve apenas 8 e o de Freitas *et al.* (2020) resultou em 18 espécies.

A análise dos biomarcadores descritos na literatura demonstrou que o critério de Park *et al.* (2022) excluiu espécies relevantes para o desfecho investigado, incluindo *Gardnerella vaginalis* (prevalência de 20,3%), *Sneathia amnii* (16,4%), *Atopobium vaginae* (21,9%) e espécies do gênero *Ureaplasma* (24,0%), todas abaixo do limiar mínimo de 25% estabelecido pelo método. Em contrapartida, o critério de Huang *et al.* (2023) preservou todos os principais biomarcadores previamente associados ao parto prematuro e produziu um número de variáveis suficientemente amplo para permitir a identificação de padrões pelos modelos sem introduzir

excesso de ruído. Adicionalmente, esse critério foi originalmente desenvolvido em contexto de integração multicoorte, característica semelhante à do presente estudo, o que reforçou sua adequação metodológica.

Após a etapa de filtragem, observou-se redução substancial da esparsidade dos dados, passando de 98,7% para 80,1% na abordagem baseada na amostra precoce e de 97,4% para 68,6% na análise com todas as coletas. Em seguida, aplicaram-se a transformação CLR e a padronização *z-score*, com verificação de consistência por meio da inspeção das médias e desvios padrão das colunas, que permaneceram próximos de zero e um em ambas as abordagens, respectivamente.

A Tabela 1 apresenta a composição final dos conjuntos de dados resultantes de cada abordagem. Na representação baseada na amostra mais precoce, o critério de Huang *et al.* (2023) reduziu o número de espécies de 2.118 para 43, com diminuição da esparsidade de 98,7% para 80,1%. Na análise utilizando todas as amostras, foram retidas 65 espécies, resultando em esparsidade de 68,6%.

Em ambos os casos, as sete métricas de diversidade alfa, a semana gestacional de coleta e os CSTs codificados via *one-hot encoding* foram incorporados como variáveis adicionais, totalizando 57 preditores na abordagem baseada na amostra precoce e 79 na abordagem com todas as coletas. Nenhum valor nulo restou após as etapas de pré-processamento.

Tabela 1 – Composição dos conjuntos de dados após filtragem de táxons e pré-processamento, por estratégia de seleção de amostras

Característica	Amostra precoce	Todas as amostras
Amostras	616	1.895
Participantes únicas	616	616
PT	349	1.223
PP	267	672
Espécies antes do filtro	2.118	2.118
Espécies após filtro	43	65
Esparsidade após filtro (%)	80,1	68,6
Variáveis de taxonomia	43	65
Variáveis de diversidade alfa	7	7
Valores nulos	0	0

Fonte: Autoria própria (2026).

Para verificar se o critério de filtragem preservou as espécies de maior relevância biológica, a Tabela 2 apresenta a prevalência e a abundância relativa dos principais biomarcadores descritos na literatura sobre microbioma vaginal e parto prematuro. As diferenças observadas entre as abordagens seguiram o padrão identificado anteriormente. Espécies dominantes, como *L. crispatus* e *L. iners*, apresentaram valores semelhantes de prevalência e abundância relativa. Em contraste, espécies associadas ao parto prematuro, como *Gardnerella vaginalis*, apresentaram prevalência substancialmente maior na análise com todas as amostras (45,5%) em comparação à abordagem baseada na amostra precoce (20,3%).

Tabela 2 – Prevalência e abundância relativa de biomarcadores reconhecidos na literatura, por estratégia de seleção de amostras

Espécie	Amostra precoce		Todas as amostras	
	Prev. (%)	Abd. (%)	Prev. (%)	Abd. (%)
<i>Lactobacillus crispatus</i>	55,2	17,61	60,3	14,47
<i>Lactobacillus iners</i>	57,3	21,95	66,5	20,83
<i>Lactobacillus jensenii</i>	40,7	5,20	50,0	3,89
<i>Lactobacillus gasseri</i>	20,3	3,33	15,3	2,68
<i>Gardnerella vaginalis</i>	20,3	1,96	45,5	3,74
<i>Sneathia amnii</i>	16,4	0,70	25,3	0,66
<i>Prevotella bivia</i>	27,6	0,85	43,8	0,95
<i>Prevotella timonensis</i>	31,5	0,84	55,4	1,43
<i>Atopobium vaginae</i>	21,9	0,78	36,8	0,89
<i>Ureaplasma</i>	24,0	0,97	38,1	0,63

Fonte: Autoria própria (2026).

4.1.2 Desempenho preditivo dos modelos

A modelagem inicial, com hiperparâmetros fixos, estabeleceu uma referência inicial para quantificar o impacto posterior da otimização. Foram avaliadas as duas estratégias de seleção de amostras combinadas com duas configurações de ponderação de classes, totalizando oito cenários. Os resultados são apresentados na Tabela 3.

Tabela 3 – Desempenho preditivo dos modelos com hiperparâmetros fixos (referência inicial), por estratégia e ponderação de classes

Estratégia	Modelo	Ponderação	AUROC	AUPR	MCC
Amostra precoce	AD	balanced	0,6591	0,6472	0,2784
Amostra precoce	FA	balanced	0,6946	0,6950	0,3071
Amostra precoce	AD	None	0,6366	0,6287	0,2258
Amostra precoce	FA	None	0,6942	0,6934	0,3100
Todas as amostras	AD	balanced	0,6168	0,5147	0,1516
Todas as amostras	FA	balanced	0,6750	0,6115	0,2903
Todas as amostras	AD	None	0,6136	0,5256	0,2323
Todas as amostras	FA	None	0,6750	0,6093	0,3283

Fonte: Autoria própria (2026).

A abordagem baseada na amostra mais precoce apresentou melhor desempenho em todos os cenários avaliados. Na FA, o AUROC atingiu 0,695 nessa abordagem, enquanto a análise com todas as amostras obteve 0,675. O mesmo padrão se repetiu na AD, com valores de 0,659 e 0,617 respectivamente.

O efeito do balanceamento de classes variou entre os modelos. Na FA utilizando a amostra precoce, a diferença no AUROC entre as configurações com e sem ponderação foi mínima (0,6946 e 0,6942). Ainda assim, o balanceamento aumentou o *recall* da classe prematuro de 0,44 para 0,50, ou seja, o modelo passou a identificar corretamente uma proporção maior de partos prematuros, ao custo de uma leve redução na precisão. Na abordagem com todas as amostras, o impacto foi mais evidente. Sem ponderação de classes, a AD apresentou *recall*

de apenas 0,21 para a classe prematuro, o que significa que o modelo deixou de identificar aproximadamente 4 em cada 5 casos de parto prematuro.

A etapa seguinte consistiu na otimização dos hiperparâmetros por busca exaustiva (*GridSearchCV*). Os melhores hiperparâmetros identificados para cada combinação de modelo e estratégia são apresentados no Quadro 3.

Quadro 3 – Melhores hiperparâmetros obtidos por busca exaustiva (*GridSearch*)

Modelo	Estratégia	Hiperparâmetros
AD	Amostra precoce	criterion=gini, max_depth=7, min_samples_leaf=20, min_samples_split=2, class_weight=balanced
AD	Todas as amostras	criterion=entropy, max_depth=15, min_samples_leaf=50, min_samples_split=2, class_weight=balanced
FA	Amostra precoce	n_estimators=100, max_features=0.3, min_samples_leaf=5, min_samples_split=2, class_weight=None, max_depth=None
FA	Todas as amostras	n_estimators=100, max_features=0.3, min_samples_leaf=1, min_samples_split=5, class_weight=balanced, max_depth=None

Fonte: Autoria própria (2026).

Ambas as árvores de decisão selecionaram `class_weight=balanced`, indicando que a ponderação favoreceu o desempenho nesse modelo. Na FA da amostra precoce, por outro lado, a configuração sem ponderação prevaleceu. O parâmetro `max_features=0.3` foi selecionado em todas as florestas, significando que cada árvore individual considerou apenas 30% das variáveis disponíveis ao realizar cada divisão. A profundidade máxima foi mantida sem limite (`max_depth=None`) em todas as florestas, conforme a formulação original de Breiman (2001a), na qual cada árvore cresce sem poda e a robustez do modelo é garantida pela agregação de múltiplos estimadores.

O desempenho dos modelos após a otimização, avaliado por validação cruzada, é apresentado na Tabela 4.

Tabela 4 – Desempenho dos modelos otimizados em validação cruzada

Estratégia	Modelo	AUROC	AUPR	MCC
Amostra precoce	AD	0,6742	0,6285	0,2579
Amostra precoce	FA	0,7154	0,7111	0,3273
Todas as amostras	AD	0,6450	0,5340	0,2048
Todas as amostras	FA	0,6932	0,6184	0,3295

Fonte: Autoria própria (2026).

A otimização elevou o desempenho em todos os cenários em relação à referência inicial. O melhor resultado geral foi obtido pela FA na estratégia de amostra precoce, com AUROC de

0,7154 e AUPR de 0,7111. A AD, na mesma estratégia, alcançou AUROC de 0,6742, resultando em uma diferença de aproximadamente 0,04 entre os dois modelos. A estratégia com todas as instâncias manteve desempenho inferior em ambos os modelos, com AUROC de 0,6450 para a AD e 0,6932 para a FA.

Para avaliar a capacidade de generalização em coortes não vistas, os modelos otimizados foram aplicados ao conjunto de validação independente composto pelas coortes Wayne State e UCSF, totalizando 134 gestantes na estratégia de amostra precoce e 302 instâncias na estratégia com todas as coletas. O desempenho dos modelos na validação cruzada e na validação independente é apresentado na Tabela 5.

Tabela 5 – Comparação de desempenho entre validação cruzada (VC) e validação independente (VI) nas coortes Wayne State e UCSF

Estratégia	Modelo	AUROC		AUPR		MCC	
		VC	VI	VC	VI	VC	VI
Amostra precoce	AD	0,6742	0,5148	0,6285	0,4047	0,2579	−0,0152
Amostra precoce	FA	0,7154	0,5100	0,7111	0,3661	0,3273	0,0581
Todas as amostras	AD	0,6450	0,5416	0,5340	0,3865	0,2048	0,1352
Todas as amostras	FA	0,6932	0,5053	0,6184	0,3563	0,3295	−0,0494

Fonte: Autoria própria (2026).

Todos os modelos apresentaram queda expressiva na validação independente. Os valores de AUROC na validação externa situaram-se entre 0,505 e 0,542, próximos ao limiar de classificação aleatória (0,50). A FA na estratégia de amostra precoce registrou a maior redução absoluta, passando de 0,7154 para 0,5100 (queda de 0,205). A AD na estratégia com todas as amostras apresentou a menor redução, de 0,6450 para 0,5416 (queda de 0,103). Os valores de MCC na validação externa foram próximos de zero ou negativos em três dos quatro cenários, indicando capacidade discriminativa praticamente nula nas coortes independentes.

As diferenças nas características populacionais entre os conjuntos de treino e de validação são apresentadas na Tabela 6.

Tabela 6 – Comparação das características populacionais entre os conjuntos de treino e de validação

Característica	Treino	Validação
Mulheres negras (%)	43,3	50,0
Mulheres brancas (%)	37,8	41,0
Semana de coleta (mediana)	17,5	13,0
PP (%)	43,3	37,3
CST I — <i>L. crispatus</i> (%)	33,1	20,1
CST IV-B (%)	8,8	30,6

Fonte: Autoria própria (2026).

A validação contém coortes inteiramente novas, não representadas no treinamento. A proporção de CST IV-B, perfil associado a maior diversidade microbiana e menor presença de *Lactobacillus*, passou de 8,8% no treino para 30,6% na validação. Simultaneamente, o CST I, dominado por *L. crispatus*, caiu de 33,1% para 20,1%. A semana mediana de coleta foi mais

precoce na validação (13,0 contra 17,5 no treino), e a proporção de mulheres de ascendência africana foi ligeiramente maior (50,0% contra 43,3%). Essas diferenças indicam que os conjuntos de treino e validação representam populações com perfis microbianos estruturalmente distintos.

O teste de permutação com 1.000 iterações, seguindo a abordagem de Napolini *et al.* (2025), confirmou que ambos os modelos predizem significativamente melhor que o acaso no conjunto de treinamento ($p = 0,001$ para ambos). A AD obteve AUROC real de 0,675 contra média permutada de 0,500, e a FA obteve 0,718 contra 0,501.

4.1.3 Biomarcadores identificados pelo modelo interpretável

A AD otimizada na estratégia de amostra precoce utilizou 16 das 57 variáveis disponíveis, concentrando o poder decisório em um subconjunto reduzido de variáveis. A importância intrínseca de cada atributo, calculada pela redução média de impureza (índice de Gini) ao longo dos nós da árvore, é apresentada na Tabela 7.

Tabela 7 – Variáveis com importância intrínseca superior a zero na AD otimizada (estratégia de amostra precoce)


Posição	Feature	Importância
1	<i>Peptoniphilus harei</i>	0,2880
2	<i>Prevotella bivia</i>	0,1052
3	<i>Lactobacillus iners</i>	0,1013
4	<i>Mycoplasma hominis</i>	0,0849
5	Semana de coleta	0,0638
6	<i>Bacteroidales</i>	0,0636
7	<i>Atopobium vaginae</i>	0,0535
8	<i>Lachnospiraceae</i>	0,0477
9	<i>Lactobacillus johnsonii</i>	0,0326
10	<i>Bacteroides vulgatus</i>	0,0306
11	<i>Fusobacterium nucleatum</i>	0,0280
12	<i>Lactobacillus vaginalis</i>	0,0249
13	Shannon	0,0206
14	<i>Aerococcus christensenii</i>	0,0204
15	Balance Weighted Phylogenetic Diversity (BWPD)	0,0200
16	<i>Lactobacillus crispatus</i>	0,0150

Fonte: Autoria própria (2026).

Peptoniphilus harei foi a variável com maior contribuição para as decisões do modelo, com importância de 0,288, valor consideravelmente superior ao das demais. Essa espécie ocupa o nó raiz da árvore, sendo o primeiro critério de divisão aplicado a todas as amostras. *Prevotella bivia* (0,105) e *Lactobacillus iners* (0,101) completam as três variáveis mais relevantes, seguidas por *Mycoplasma hominis* (0,085) e a semana de coleta (0,064). Dentre as 16 variáveis utilizadas, 13 são espécies microbianas, 2 são métricas de diversidade alfa (Shannon e BWPD) e 1 é a variável clínica de semana de coleta.

A estrutura da árvore, visualizada na Figura 3, permite acompanhar o encadeamento das decisões. A partir do nó raiz (*Peptoniphilus harei*), as ramificações subsequentes incorporam *Prevotella bivia*, *Lactobacillus iners*, *Atopobium vaginae* e *Bacteroidales*, formando regras do tipo se-então que podem ser percorridas individualmente. Cada caminho da raiz até uma folha corresponde a uma combinação específica de condições microbianas que leva à classificação de parto a termo ou prematuro.

Figura 3 – Estrutura da AD otimizada na estratégia de amostra precoce (primeiros 4 níveis)



Fonte: Autoria própria (2026).

A análise via SHAP aplicada à própria AD confirmou o ranqueamento obtido pela importância intrínseca. *Peptoniphilus harei*, *Lactobacillus iners* e *Prevotella bivia* permaneceram nas três primeiras posições, com valores SHAP médios absolutos de magnitude compatível com as importâncias baseadas em Gini.

4.1.4 Biomarcadores identificados pelo modelo opaco

A FA otimizada, composta por 100 árvores sem limite de profundidade, distribuiu a importância de forma mais uniforme entre as variáveis, comportamento característico de modelos de *ensemble*. O ranqueamento das 20 variáveis mais relevantes por importância intrínseca (média da redução de impureza entre todas as árvores) é apresentado na Tabela 8.

Tabela 8 – Os 20 preditores com maior importância intrínseca na FA otimizada (estratégia de amostra precoce)


Posição	Preditor	Importância
1	<i>Prevotella bivia</i>	0,0604
2	<i>Peptoniphilus harei</i>	0,0488
3	<i>Lactobacillus iners</i>	0,0486
4	collect_wk	0,0476
5	<i>Prevotella buccalis</i>	0,0457
6	Bacteroidales não classificadas	0,0383
7	<i>Corynebacterium tuberculostearicum</i>	0,0364
8	rooted_pd	0,0299
9	BWPD	0,0297
10	<i>Corynebacterium aurimucosum</i>	0,0254
11	<i>Gardnerella vaginalis</i>	0,0250
12	<i>Bacteroides vulgatus</i>	0,0234
13	<i>Lactobacillus crispatus</i>	0,0217
14	inv_simpson	0,0208
15	<i>Lactobacillus johnsonii</i>	0,0202
16	<i>Lactobacillus jensenii</i>	0,0202
17	<i>Lactobacillus vaginalis</i>	0,0202
18	unrooted_pd	0,0199
19	phylo_entropy	0,0187
20	Firmicutes	0,0187

Fonte: Autoria própria (2026).

As três espécies mais importantes (*Prevotella bivia*, *Peptoniphilus harei* e *Lactobacillus iners*) coincidem com as três primeiras da AD, embora em ordem diferente e com valores de importância substancialmente menores e mais distribuídos. Enquanto na AD a primeira variável concentrou 28,8% da importância total, na FA a primeira variável acumulou apenas 6,0%, refletindo a dispersão inerente aos modelos de *ensemble*. Diferentemente da AD, a FA atribuiu importância relevante a métricas de diversidade alfa (*rooted_pd*, BWPD, *inv_simpson*, *unrooted_pd* e *phylo_entropy*) e a espécies ausentes no ranqueamento do modelo interpretável, como *Corynebacterium tuberculostearicum*, *Corynebacterium aurimucosum* e *Gardnerella vaginalis*.

A análise SHAP da FA produziu um ranqueamento parcialmente diferente do obtido pela importância intrínseca. *Lactobacillus iners* subiu para a primeira posição, seguida por *Prevotella bivia* e *Peptoniphilus harei*. *Ureaplasma*, ausente no *top 15* por importância intrínseca, apareceu na 11ª posição pelo SHAP. As métricas de diversidade alfa ganharam posições mais altas (*unrooted_pd*, *phylo_entropy* e *inv_simpson* entre as 15 primeiras). O *summary plot* do SHAP, apresentado na Figura 4, permite visualizar não apenas a magnitude da contribuição de cada variável, mas também a direção do efeito. Valores elevados de *Lactobacillus iners* e *Prevotella bivia* tenderam a empurrar a predição em direção ao parto prematuro, enquanto valores elevados de métricas como *rooted_pd* apresentaram efeito variável.

Figura 4 – *Summary plot* do SHAP para a FA otimizada na estratégia de amostra precoce (20 preditores mais relevantes)



Fonte: Autoria própria (2026).

4.1.5 Comparação entre os ranqueamentos de biomarcadores

Os quinze atributos mais relevantes segundo cada abordagem de importância (intrínseca e SHAP, para ambos os modelos) são apresentados no Quadro 4, permitindo comparar a concordância entre o modelo interpretável e o opaco.

Quadro 4 – Quinze atributos mais relevantes por abordagem de importância (estratégia de amostra precoce)

#	AD (intríns.)	FA (intríns.)	AD (SHAP)	FA (SHAP)
1	<i>Peptoniphilus harei</i>	<i>Prevotella bivia</i>	<i>Peptoniphilus harei</i>	<i>Lactobacillus iners</i>
2	<i>Prevotella bivia</i>	<i>Peptoniphilus harei</i>	<i>Lactobacillus iners</i>	<i>Prevotella bivia</i>
3	<i>Lactobacillus iners</i>	<i>Lactobacillus iners</i>	<i>Prevotella bivia</i>	<i>Peptoniphilus harei</i>
4	<i>Mycoplasma hominis</i>	collect_wk	<i>Bacteroides vulgatus</i>	<i>Prevotella buccalis</i>
5	collect_wk	<i>Prevotella buccalis</i>	<i>Atopobium vaginae</i>	uncl. <i>Bacteroidales</i>
6	<i>Bacteroidales</i>	uncl. <i>Bacteroidales</i>	collect_wk	collect_wk
7	<i>Atopobium vaginae</i>	<i>C. tuberculostrictum</i>	<i>Bacteroidales</i>	<i>Bacteroides vulgatus</i>
8	<i>Lachnospiraceae</i>	rooted_pd	<i>Mycoplasma hominis</i>	<i>C. tuberculostrictum</i>
9	<i>Lactobacillus johnsonii</i>	BWPD	<i>Lachnospiraceae</i>	<i>Bacteroidales</i>
10	<i>Bacteroides vulgatus</i>	<i>C. aurimucosum</i>	<i>Fusobacterium nucleatum</i>	<i>C. aurimucosum</i>
11	<i>Fusobacterium nucleatum</i>	<i>Gardnerella vaginalis</i>	shannon	<i>Ureaplasma</i>
12	<i>Lactobacillus vaginalis</i>	<i>Bacteroides vulgatus</i>	<i>Lactobacillus vaginalis</i>	phylo_entropy
13	shannon	<i>Lactobacillus crispatus</i>	<i>Lactobacillus johnsonii</i>	unrooted_pd
14	<i>Aerococcus christensenii</i>	inv_simpson	<i>Aerococcus christensenii</i>	inv_simpson
15	BWPD	<i>Lactobacillus johnsonii</i>	<i>Lactobacillus crispatus</i>	rooted_pd

Fonte: Autoria própria (2026).

Três espécies se mantiveram consistentemente nas primeiras posições de todos os quatro ranqueamentos: *Peptoniphilus harei*, *Prevotella bivia* e *Lactobacillus iners*. Na comparação por importância intrínseca, 7 das 15 variáveis foram compartilhadas entre os dois modelos. Na comparação via SHAP, a concordância foi de 6 atributos em comum.

A AD apresentou preditores semelhantes entre seus dois métodos de interpretação (intrínseco e SHAP). Na FA, a diferença entre os métodos foi mais acentuada, com *Ureaplasma* aparecendo na 11ª posição pelo SHAP apesar de não figurar no *top 15* por importância intrínseca, e métricas de diversidade alfa como phylo_entropy e unrooted_pd ganhando posições mais altas no SHAP.

As variáveis exclusivas de cada modelo também diferiram. A AD priorizou espécies como *Mycoplasma hominis*, *Atopobium vaginae* e *Fusobacterium nucleatum*, enquanto a FA destacou *Prevotella buccalis*, *Corynebacterium tuberculostrictum*, *Gardnerella vaginalis* e múltiplas métricas de diversidade alfa.

4.1.6 Confiabilidade estatística dos biomarcadores

As espécies cuja abundância diferiu de forma estatisticamente significativa entre os grupos, segundo o teste de Mann-Whitney com correção de Benjamini-Hochberg ($q < 0,1$), são apresentadas na Tabela 9. Nesta e nas demais tabelas desta seção, o símbolo ↑ PP indica maior abundância no grupo de PP, e ↓ PP indica maior abundância no grupo de PT.

Tabela 9 – Espécies com diferença de abundância estatisticamente significativa entre PT e PP, pelo teste de Mann-Whitney com correção de Benjamini-Hochberg ($q < 0,1$)

(continua)

Espécie	Direção	Média PT	Média PP	q-value
<i>Peptoniphilus harei</i>	↑ PP	0,00101	0,00482	4,44e-14
<i>Prevotella bivia</i>	↑ PP	0,00193	0,01716	2,03e-09
<i>Staphylococcus epidermidis</i>	↑ PP	0,00179	0,00604	4,07e-06
<i>Finnegoldia magna</i>	↑ PP	0,00390	0,00720	6,03e-06
<i>Ureaplasma</i>	↑ PP	0,00517	0,01572	6,03e-06
<i>Lactobacillus iners</i>	↑ PP	0,18755	0,26120	6,03e-06
<i>Weissella</i>	↓ PP	0,17351	0,07701	2,06e-05
<i>Streptococcus anginosus</i>	↑ PP	0,00026	0,01475	4,94e-05
<i>Prevotella timonensis</i>	↑ PP	0,00509	0,01268	1,32e-04
<i>Atopobium vaginae</i>	↓ PP	0,00838	0,00701	1,65e-04
<i>Firmicutes</i>	↓ PP	0,02876	0,01049	1,85e-04
<i>Megasphaera</i>	↑ PP	0,01286	0,01789	4,90e-04
<i>Fusobacterium nucleatum</i>	↑ PP	0,00004	0,00244	1,55e-03
<i>Lactobacillus gasseri</i>	↓ PP	0,04063	0,02361	1,96e-03
<i>Aerococcus christensenii</i>	↓ PP	0,00783	0,00244	2,12e-03
<i>L. gasseri/paragasseri</i>	↓ PP	0,02244	0,00579	4,73e-03
<i>Chloroflexi</i>	↓ PP	0,00396	0,00124	7,20e-03
<i>Terrabacteria group</i>	↓ PP	0,02226	0,01403	8,02e-03
<i>Bacteroides vulgatus</i>	↑ PP	0,00108	0,00203	1,17e-02
<i>Sneathia amnii</i>	↑ PP	0,00471	0,00990	1,78e-02
<i>Anaerococcus vaginalis</i>	↑ PP	0,00053	0,00173	7,97e-02
<i>Sneathia sanguinegens</i>	↑ PP	0,00166	0,01046	9,05e-02

Fonte: Autoria própria (2026)

Das 43 espécies testadas, 22 apresentaram diferença significativa com $q < 0,1$, sendo 20 com $q < 0,05$. As espécies com menor q-value foram *Peptoniphilus harei* ($q = 4,44 \times 10^{-14}$), *Prevotella bivia* ($q = 2,03 \times 10^{-9}$) e *Staphylococcus epidermidis* ($q = 4,07 \times 10^{-6}$). Entre as espécies com abundância aumentada no grupo de parto prematuro estão *Peptoniphilus harei*, *Prevotella bivia*, *Ureaplasma*, *Lactobacillus iners*, *Sneathia amnii* e *Prevotella timonensis*. Entre aquelas com abundância reduzida no grupo prematuro encontram-se *Weissella*, *Lactobacillus gasseri*, *Aerococcus christensenii* e *Atopobium vaginae*.

O cruzamento entre a relevância nos modelos e a significância estatística resultou no conjunto de biomarcadores consolidados, apresentado na Tabela 10. O critério de inclusão foi figurar entre os quinze atributos mais relevantes em ao menos um dos quatro ranqueamentos

(importância intrínseca e SHAP de ambos os modelos) e, simultaneamente, apresentar $q < 0,1$ no teste de Mann-Whitney.

Tabela 10 – Biomarcadores consolidados: presentes entre os quinze mais relevantes em ao menos um modelo e estatisticamente significativos
($q < 0,1$)

Espécie	Direção	q-value
<i>Peptoniphilus harei</i>	↑ PP	4,44e-14
<i>Prevotella bivia</i>	↑ PP	2,03e-09
<i>Lactobacillus iners</i>	↑ PP	6,03e-06
<i>Ureaplasma</i>	↑ PP	6,03e-06
<i>Atopobium vaginae</i>	↓ PP	1,65e-04
<i>Fusobacterium nucleatum</i>	↑ PP	1,55e-03
<i>Aerococcus christensenii</i>	↓ PP	2,12e-03
<i>Bacteroides vulgatus</i>	↑ PP	1,17e-02

Fonte: Autoria própria (2026).

Oito espécies atenderam a ambos os critérios. Cinco apresentaram abundância aumentada no grupo de parto prematuro (*Peptoniphilus harei*, *Prevotella bivia*, *Lactobacillus iners*, *Ureaplasma*, *Fusobacterium nucleatum* e *Bacteroides vulgatus*) e duas apresentaram abundância reduzida (*Atopobium vaginae* e *Aerococcus christensenii*). As três espécies que figuraram nas primeiras posições de todos os quatro ranqueamentos na seção anterior (*Peptoniphilus harei*, *Prevotella bivia* e *Lactobacillus iners*) apresentaram os menores *q-values* entre os biomarcadores consolidados, com valores inferiores a 10^{-5} .

A confiabilidade do desempenho dos modelos foi verificada pelo teste de permutação com 1.000 iterações, seguindo a abordagem de Naspolini *et al.* (2025). Os resultados são apresentados na Tabela 11.

Tabela 11 – Resultado do teste de permutação (1.000 iterações) para os modelos da estratégia de amostra precoce

Modelo	AUROC real	AUROC acaso	<i>p-value</i>
AD	0,6752	0,5003	0,0010
FA	0,7182	0,5013	0,0010

Fonte: Autoria própria (2026).

Ambos os modelos obtiveram AUROC real substancialmente superior à média permutada ($p = 0,001$). A AD alcançou 0,6752 contra 0,5003 no acaso, e a FA obteve 0,7182 contra 0,5013. Esses valores confirmam que os padrões identificados pelos modelos nos dados de treinamento não são artefatos estatísticos, e que as importâncias atribuídas às variáveis refletem associações genuínas entre a composição do microbioma vaginal e o desfecho do parto.

4.2 Discussão

A presente discussão tem como objetivo interpretar criticamente os resultados obtidos neste estudo à luz da literatura sobre microbioma vaginal, parto prematuro e aprendizado de máquina interpretável. Inicialmente, é analisada a relação entre interpretabilidade e capacidade preditiva dos modelos avaliados, investigando se os ganhos de desempenho observados justificam o aumento da complexidade dos métodos utilizados. Em seguida, discute-se a consistência dos biomarcadores identificados em comparação com evidências previamente reportadas, bem como a confiabilidade das diferentes abordagens de interpretação empregadas. Por fim, são apresentadas as principais limitações do estudo e suas implicações para o desenvolvimento futuro de modelos preditivos e para a potencial aplicação clínica desses achados.

4.2.1 Relação entre interpretabilidade e capacidade preditiva

A questão central deste trabalho consistiu em avaliar se os ganhos em capacidade preditiva obtidos por modelos opacos justificam a perda de interpretabilidade na identificação de biomarcadores do microbioma vaginal associados ao parto prematuro. Os resultados obtidos permitem uma resposta fundamentada.

Na validação cruzada interna, a FA superou a AD em aproximadamente 0,04 de AUROC na estratégia de amostra precoce (0,7154 contra 0,6742). Essa diferença, embora estatisticamente detectável, é modesta quando comparada à variabilidade inerente ao problema. Huang *et al.* (2023), em sua meta-análise de 12 coortes, reportaram AUROC variando de 0,28 a 0,79 entre conjuntos de dados independentes, uma faixa de variação que supera amplamente a diferença entre os dois modelos avaliados neste trabalho.

A avaliação nas coortes independentes Wayne State e UCSF trouxe um resultado ainda mais contundente. A vantagem da FA sobre a AD desapareceu por completo, com ambos os modelos apresentando AUROC próximo de 0,51. A FA, que havia demonstrado o melhor desempenho interno, sofreu a maior queda absoluta ($-0,205$), enquanto a AD apresentou queda de $-0,159$ na mesma estratégia. Esse padrão é consistente com o sobreajuste detectado durante a otimização, em que a FA apresentou AUROC de 0,992 no conjunto de treinamento contra 0,718 na validação cruzada, uma diferença de 0,274. Na AD, essa diferença foi de 0,153, indicando menor propensão à memorização dos dados.

Esses achados dialogam diretamente com o argumento de Rudin (2019), segundo o qual não há comprovação consistente de que modelos opacos apresentem desempenho superior aos interpretáveis quando avaliados de forma rigorosa. A autora sustenta que, em aplicações de alto risco, a complexidade adicional frequentemente gera uma falsa sensação de superioridade, que se dissolve diante de dados novos. Os resultados deste trabalho corroboram essa perspectiva no domínio específico da predição de parto prematuro a partir do microbioma vaginal.

A noção de que interpretabilidade e precisão são objetivos necessariamente opostos, discutida na Seção 2.2.4, tampouco encontrou sustentação nos dados. Breiman (2001b) questionou o chamado Dilema de Occam, que pressupõe que modelos mais simples são inerentemente superiores ou mais verdadeiros. O autor demonstrou que, para um mesmo problema de predição, pode existir um conjunto de modelos com desempenhos estatisticamente equivalentes, fenômeno que denominou Efeito Rashomon. Rudin (2025) argumenta que esse efeito anula o suposto conflito entre precisão e interpretabilidade, pois se há muitos modelos com resultados equivalentes, é altamente provável que ao menos alguns deles sejam também interpretáveis. Os resultados do DREAM Challenge corroboram esse fenômeno na prática, uma vez que Golob *et al.* (2024) destacaram a disponibilidade de múltiplos modelos desenvolvidos de forma independente com desempenhos preditivos próximos entre si. De modo similar, Park *et al.* (2022) demonstraram que o modelo GUIDE, baseado em uma árvore de decisão única, alcançou AUROC de 0,77 com interpretação biológica direta, frente ao AUROC de 0,84 da FA na mesma coorte, uma diferença de 0,07 comparável à observada neste trabalho. A diferença de 0,04 em AUROC entre a AD e a FA obtida neste estudo situa ambos os modelos dentro dessa faixa de equivalência, especialmente considerando que Huang *et al.* (2023) reportaram variação de 0,28 a 0,79 entre coortes independentes para o mesmo desfecho. Esses achados reforçam que a escolha pelo modelo transparente não implicou sacrifício relevante de desempenho.

4.2.2 Consistência dos biomarcadores frente à literatura

Dos oito biomarcadores consolidados neste trabalho, a maioria encontra respaldo em estudos anteriores sobre microbioma vaginal e parto prematuro. *Prevotella bivia*, a espécie com segundo menor q -value ($2,03 \times 10^{-9}$), é frequentemente associada a vaginose bacteriana e ao parto prematuro (Chakoory *et al.*, 2024; Fettweis *et al.*, 2019; Park *et al.*, 2022). *Lactobacillus iners*, terceiro biomarcador mais consistente, é reconhecido na literatura como um lactobacilo com menor capacidade protetora devido ao seu genoma reduzido e à produção limitada de ácido láctico (Witkin, 2015), tendo sido associado ao parto prematuro por Chakoory *et al.* (2024), Huang *et al.* (2023) e Freitas *et al.* (2020). *Ureaplasma*, identificado como biomarcador consolidado com abundância aumentada no grupo prematuro, foi destacado por Park *et al.* (2022) como espécie relevante na predição do desfecho gestacional.

Peptoniphilus harei, a espécie com maior significância estatística ($q = 4,44 \times 10^{-14}$) e que ocupou as primeiras posições em todos os ranqueamentos, recebeu menos atenção na literatura sobre parto prematuro em comparação com *Gardnerella* ou *Prevotella*. Contudo, Park *et al.* (2022) identificaram *Peptoniphilus grossensis* como espécie relevante para a predição de parto prematuro em uma coorte coreana. A consistência com que *P. harei* emergiu nos dois modelos e em ambos os métodos de interpretação sugere que essa espécie merece investigação mais aprofundada como potencial biomarcador.

Um achado que contrasta com a literatura foi a ausência de *Gardnerella vaginalis* entre os biomarcadores consolidados. Apesar de ser amplamente reportada como associada ao parto prematuro (Chakoory *et al.*, 2024; Fettweis *et al.*, 2019; Huang *et al.*, 2023; Li *et al.*, 2024; Golob *et al.*, 2024), essa espécie apresentou $q = 0,936$ no teste de Mann-Whitney, indicando que sua abundância não diferiu significativamente entre os grupos neste conjunto de dados. Esse resultado pode ter múltiplas explicações. Huang *et al.* (2023) observaram que a eficiência na detecção de *Gardnerella* varia conforme a região do gene 16S rRNA amplificada, sendo que *primers* da região V1-V2 apresentam menor sensibilidade para essa espécie em comparação aos da região V4. Além disso, a utilização da amostra mais precoce de cada gestante pode ter captado um momento gestacional em que a diferenciação entre grupos ainda não era pronunciada para essa espécie específica. Liao *et al.* (2023) demonstraram que a microdiversidade de *Gardnerella* é mais informativa que sua abundância total, uma dimensão não capturada pela taxonomia baseada em 16S rRNA utilizada neste trabalho.

A direção das associações observadas é coerente com o modelo biológico descrito na literatura. As espécies com abundância aumentada no grupo prematuro (*Peptoniphilus harei*, *Prevotella bivia*, *L. iners*, *Ureaplasma*, *Fusobacterium nucleatum* e *Bacteroides vulgatus*) são majoritariamente anaeróbias ou associadas a processos inflamatórios do trato genital (Fettweis *et al.*, 2019; Witkin, 2015). As espécies com abundância reduzida (*Aerococcus christensenii* e *Atopobium vaginae*) seguem padrões menos descritos na literatura, sendo que *A. vaginae* é tipicamente associada à vaginose bacteriana, mas sua relação com o parto prematuro é mais variável entre estudos (Park *et al.*, 2022).

4.2.3 Confiabilidade das explicações: SHAP versus importância intrínseca

A comparação entre os métodos de interpretação revelou padrões distintos de consistência conforme o tipo de modelo. Na AD, os ranqueamentos por importância intrínseca e por SHAP foram altamente concordantes, com as mesmas três espécies nas primeiras posições em ambos os métodos. Essa consistência é esperada em modelos transparentes, cuja lógica de decisão é diretamente acessível e não requer aproximações externas para ser compreendida.

Na FA, a concordância entre os dois métodos foi menor. *Ureaplasma*, ausente no *top* 15 por importância intrínseca, emergiu na 11^a posição pelo SHAP. Métricas de diversidade alfa como *phylo_entropy* e *unrooted_pd* ganharam posições mais altas no SHAP em comparação com o *ranking* intrínseco. Essas divergências ilustram a limitação dos métodos *post-hoc* discutida por Rudin *et al.* (2022), que argumentam que explicações externas podem não refletir fielmente o funcionamento interno do modelo, tornando difícil determinar se a discrepância se origina do modelo ou do explicador.

Essa observação tem implicações práticas relevantes. Quando dois métodos de interpretação aplicados ao mesmo modelo divergem sobre quais variáveis são mais importantes, o profissional que utiliza essas informações para fundamentar decisões clínicas enfrenta uma ambiguidade que não existe no modelo interpretável. Na AD, as regras de decisão são explícitas e homogêneas. Na FA, o profissional depende de uma camada adicional de análise cujas conclusões podem variar conforme o método empregado.

A convergência dos três biomarcadores centrais (*Peptoniphilus harei*, *Prevotella bivia* e *Lactobacillus iners*) em todos os quatro *rankings* sugere que os padrões microbianos mais fortes são capturados independentemente do modelo ou do método de interpretação. As divergências concentraram-se em variáveis de importância secundária, cujas posições oscilaram entre os ranqueamentos. Esse achado indica que, para os biomarcadores mais robustos, a escolha do modelo não altera a conclusão biológica, enquanto para biomarcadores de menor expressão a interpretação torna-se dependente da abordagem utilizada, comprometendo sua confiabilidade.

4.2.4 Limitações do estudo

Este trabalho apresenta limitações que devem ser consideradas na interpretação dos resultados.

A queda acentuada de desempenho na validação independente indica que os padrões microbianos aprendidos pelos modelos não se transferiram adequadamente para as coortes Wayne State e UCSF. As diferenças populacionais identificadas entre treino e validação, como a distribuição distinta de CST (IV-B saltando de 8,8% para 30,6%) e a composição racial diferente, sugerem que a heterogeneidade intercoorte constitui uma barreira fundamental para a generalização de modelos preditivos baseados no microbioma vaginal. Essa limitação não é

exclusiva deste estudo, sendo reconhecida por Gudnadottir *et al.* (2022), Huang *et al.* (2023) e Golob *et al.* (2024) como um desafio estrutural do campo.

O conjunto de dados utilizado, embora proveniente de uma iniciativa de larga escala, é composto exclusivamente por dados de sequenciamento do gene 16S rRNA, que limita a resolução taxonômica ao nível de gênero e espécie. Liao *et al.* (2023) demonstraram que a microdiversidade genética das espécies, acessível apenas por metagenômica *shotgun*, pode ser mais informativa para a predição de parto prematuro. Da mesma forma, Kindschuh *et al.* (2023) mostraram que o metaboloma vaginal apresentou AUROC de 0,78, superando o microbioma (0,55) na mesma coorte, sugerindo que dados ômicos complementares podem capturar informações preditivas que a taxonomia isolada não alcança.

A utilização de apenas uma amostra por gestante na estratégia principal, embora respaldada pela literatura (Fettweis *et al.*, 2019; Gudnadottir *et al.*, 2022) e justificada empiricamente pela preservação dos sinais microbianos precoces, descartou informação longitudinal que poderia ser explorada por modelos temporais mais sofisticados. A estratégia com todas as instâncias, mantida para comparação, apresentou desempenho inferior, mas abordagens como ponderação temporal das amostras não foram testadas.

4.2.5 Implicações para o uso clínico

Os resultados deste trabalho oferecem subsídios para a reflexão sobre a adoção de modelos preditivos baseados no microbioma vaginal em contextos clínicos.

A capacidade da AD de identificar os mesmos biomarcadores centrais que a FA, com desempenho preditivo equivalente na validação externa, reforça a viabilidade de modelos interpretáveis para esse tipo de aplicação. Em um cenário clínico, a possibilidade de apresentar ao profissional de saúde as regras explícitas que fundamentam uma predição, como as extraídas da árvore de decisão treinada neste trabalho, oferece uma base de confiança que métodos *post-hoc* não conseguem garantir com a mesma solidez. Conforme argumentado por Rudin (2019), em decisões de alto risco é preferível um modelo cujas justificativas são parte integrante de sua estrutura a um modelo que depende de explicações externas potencialmente inconsistentes.

O teste de permutação confirmou que ambos os modelos capturam padrões genuínos nos dados de treinamento ($p = 0,001$), validando a relevância biológica dos biomarcadores identificados. Contudo, a incapacidade de generalização para coortes independentes indica que a tradução desses achados em ferramentas diagnósticas de aplicação ampla ainda enfrenta desafios. A padronização de protocolos de coleta e sequenciamento, a inclusão de coortes populacionalmente diversas no treinamento e a integração de dados multiômicos são caminhos apontados pela literatura (Golob *et al.*, 2024; Kindschuh *et al.*, 2023; Liao *et al.*, 2023) para superar essas barreiras.

A identificação de *Peptoniphilus harei* como o biomarcador mais consistente nos modelos e com a maior significância estatística representa um achado potencialmente relevante para investigações futuras. Embora menos estudado que *Gardnerella* ou *Prevotella* no contexto do

parto prematuro, sua presença robusta nos *rankings* de ambos os modelos, associada a um *q-value* de $4,44 \times 10^{-14}$, sugere que seu papel na dinâmica do microbioma vaginal durante a gestação merece aprofundamento. Estudos futuros com metagenômica *shotgun* e dados funcionais poderiam elucidar os mecanismos pelos quais essa espécie se associa ao desfecho gestacional adverso.

5 CONCLUSÃO

Este trabalho teve como objetivo avaliar se ganhos em capacidade preditiva justificam a menor interpretabilidade na identificação de biomarcadores do microbioma vaginal para a predição de PP. Para isso, foram treinados e comparados dois modelos de AM com níveis distintos de transparência, uma AD (modelo interpretável) e uma FA (modelo opaco interpretado via SHAP), utilizando dados públicos do *Microbiome Preterm Birth DREAM Challenge* (Golob *et al.*, 2024).

Em relação ao primeiro objetivo específico, a modelagem preditiva para classificar o desfecho do parto, ambos os modelos foram treinados com dados de abundância relativa do microbioma vaginal de 616 gestantes, após pré-processamento que incluiu a seleção da amostra mais precoce por gestante, filtragem de táxons raros pelo critério de Huang *et al.* (2023), transformação CLR e padronização *z-score*. A FA obteve AUROC de 0,715 na validação cruzada, enquanto a AD alcançou 0,674, uma diferença de aproximadamente 0,04. Ambos os valores são compatíveis com os reportados na literatura para o mesmo desfecho e tipo de dado (Huang *et al.*, 2023; Golob *et al.*, 2024).

Quanto ao segundo objetivo, a comparação dos microrganismos com maior contribuição para os desfechos, três espécies foram consistentemente identificadas nas primeiras posições de todos os ranqueamentos de importância, independentemente do modelo ou do método de interpretação empregado: *Peptoniphilus harei*, *Prevotella bivia* e *Lactobacillus iners*. A AD identificou esses mesmos biomarcadores centrais sem necessidade de técnicas *post-hoc*, por meio da inspeção direta de sua estrutura de regras.

O terceiro objetivo, a determinação do grau de incerteza na identificação dos biomarcadores, foi atendido pelos testes de Mann-Whitney com correção de Benjamini-Hochberg, que identificaram 22 espécies com diferença significativa de abundância entre os grupos ($q < 0,1$). O cruzamento entre relevância nos modelos e significância estatística resultou em oito biomarcadores consolidados. O teste de permutação, seguindo a abordagem de Naspolini *et al.* (2025), confirmou que ambos os modelos capturam padrões genuínos nos dados ($p = 0,001$), validando a confiabilidade das importâncias atribuídas.

Em relação ao quarto objetivo, a discussão sobre a relação entre interpretabilidade, capacidade preditiva e confiabilidade, os resultados convergiram para uma constatação central. A vantagem preditiva da FA sobre a AD, embora detectável na validação cruzada interna, desapareceu na validação independente com as coortes Wayne State e UCSF, onde ambos os modelos apresentaram AUROC próximo de 0,51. A FA sofreu a maior queda absoluta ($-0,205$), associada a indícios de sobreajuste. Paralelamente, a análise SHAP da FA revelou divergências em relação à sua própria importância intrínseca, enquanto na AD os dois métodos de interpretação foram concordantes. Esses achados corroboram o argumento de Rudin (2019) de que, em aplicações de alto risco, a complexidade adicional de modelos opacos pode gerar uma falsa sensação de superioridade sem entregar ganho real de generalização.

Portanto, no contexto da predição de PP a partir do microbioma vaginal, os resultados deste trabalho sustentam que a priorização de modelos interpretáveis é uma escolha metodologicamente segura. A AD identificou os mesmos biomarcadores centrais que a FA, com desempenho preditivo equivalente em dados independentes e com explicações diretamente acessíveis a partir de sua estrutura. Para aplicações clínicas, onde a compreensão do raciocínio do modelo é condição necessária para a confiança do profissional de saúde, essa transparência representa uma vantagem concreta sobre modelos cuja interpretação depende de aproximações externas (Rudin *et al.*, 2022; Hulsen, 2023).

Como trabalhos futuros, sugere-se a inclusão de dados multiômicos, como o metaboloma vaginal, que demonstrou potencial preditivo superior ao microbioma em estudos anteriores (Kindschuh *et al.*, 2023). A investigação do papel de *Peptoniphilus harei*, biomarcador mais consistente neste estudo e ainda pouco explorado na literatura, com dados de metagenômica *shotgun* e análise funcional, pode contribuir para a compreensão dos mecanismos biológicos envolvidos (Liao *et al.*, 2023). A ampliação dos conjuntos de treinamento com coortes populacionalmente diversas e a padronização de protocolos de coleta e sequenciamento são caminhos necessários para superar as barreiras de generalização identificadas (Gudnadottir *et al.*, 2022; Huang *et al.*, 2023). Por fim, a avaliação de modelos interpretáveis mais recentes, como listas de regras e modelos aditivos generalizados, poderia ampliar o repertório de alternativas transparentes com desempenho competitivo (Rudin *et al.*, 2022).

REFERÊNCIAS

- BECK, S. *et al.* The worldwide incidence of preterm birth: a systematic review of maternal mortality and morbidity. **Bulletin of the World Health Organization**, SciELO Public Health v. 88,, p. 31–38, 2010. Disponível em: <https://doi.org/10.2471/BLT.08.062554>. Acesso em: 03 out. 2025.
- BISONG, E. Google colabory. *In: Building Machine Learning and Deep Learning Models on Google Cloud Platform*. Berkeley, CA: Apress 2019. Disponível em: https://doi.org/10.1007/978-1-4842-4470-8_7. Acesso em: 10 out. 2025.
- BRADLEY, E. *et al.* Nascidos muito cedo: epidemiologia global do parto prematuro e fatores de mudança. **Reproductive Health**, v. 22, n. Supl. 2, p. 105, 2025. Disponível em: <https://doi.org/10.1186/s12978-025-02033-x>. Acesso em: 08 set. 2025.
- BREIMAN, L. Random forests. **Machine Learning**, Springer v. 45, n. 1, p. 5–32, 2001. Disponível em: <https://doi.org/10.1023/A:1010933404324>. Acesso em: 28 set. 2025.
- BREIMAN, L. Statistical modeling: The two cultures (with comments and a rejoinder by the author). **Statistical Science**, Institute of Mathematical Statistics v. 16, n. 3, p. 199–231, 2001. Disponível em: <https://doi.org/10.1214/ss/1009213726>. Acesso em: 29 set. 2025.
- BREIMAN, L. *et al.* **Classification and Regression Trees**. 1. ed. Chapman and Hall/CRC, 1984. Disponível em: <https://doi.org/10.1201/9781315139470>. Acesso em: 26 set. 2025.
- CHAKOORY, O. *et al.* Deepmptb: uma rede neural profunda baseada no microbioma vaginal como estratégia de inteligência artificial para previsão eficiente de parto prematuro. **Biomarker Research**, v. 12,, p. 25, 2024. Disponível em: <https://doi.org/10.1186/s40364-024-00557-1>. Acesso em: 20 ago. 2025.
- CHU, D. M. *et al.* The microbiome in preterm birth. **Best Practice & Research Clinical Obstetrics & Gynaecology**, Elsevier v. 52,, p. 103–113, 2018. Disponível em: <https://doi.org/10.1016/j.bpobgyn.2018.03.006>. Acesso em: 01 out. 2025.
- ELSHAWI, R.; AL-MALLAH, A. A.; SAKR, M. A. Interpretability in healthcare: A comparative study of local machine learning interpretability techniques. **Computational Intelligence**, v. 37, n. 4, p. 1633–1650, 2021. Disponível em: <https://doi.org/10.1111/coin.12410>. Acesso em: 16 set. 2025.
- EYSENCK, M. W.; EYSENCK, C. **Inteligência artificial X humanos: o que a ciência cognitiva nos ensina ao colocar frente a frente a mente humana e a IA**. Porto Alegre: ArtMed, 2023. E-book. p.224. ISBN 9786558821106. Disponível em: <https://app.minhabiblioteca.com.br/reader/books/9786558821106/>. Acesso em: 26 set. 2025.
- FACELI, K. *et al.* **Inteligência Artificial – Uma Abordagem de Aprendizado de Máquina**. 3. ed. Rio de Janeiro: LTC, 2025. E-book. p.2. ISBN 9788521639213. Disponível em: <https://app.minhabiblioteca.com.br/reader/books/9788521639213/>. Acesso em: 22 set. 2025.
- FETTWEIS, J. M. *et al.* The vaginal microbiome and preterm birth. **Nature Medicine**, v. 25,, p. 1012–1021, 2019. Disponível em: <https://doi.org/10.1038/s41591-019-0450-2>. Acesso em: 12 ago. 2025.
- FREITAS, A. S. de *et al.* Defining microbial biomarkers for risk of preterm labor. **Brazilian Journal of Microbiology**, v. 51, n. 1, p. 151–159, 2020. Disponível em: <https://doi.org/10.1007/s42770-019-00118-x>. Acesso em: 13 ago. 2025.

GAO, W. *et al.* Multimodal metagenomic analysis reveals microbial single nucleotide variants as superior biomarkers for early detection of colorectal cancer. **Gut Microbes**, v. 15, n. 2, p. 2245562, 2023. Disponível em: <https://doi.org/10.1080/19490976.2023.2245562>. Acesso em: 17 maio 2026.

GOLOB, J. L. *et al.* Microbiome preterm birth dream challenge: Crowdsourcing machine learning approaches to advance preterm birth research. **Cell Reports Medicine**, v. 5, p. 101350, 2024. Disponível em: <https://doi.org/10.1016/j.xcrm.2023.101350>. Acesso em: 15 ago. 2025.

GREENER, J. G. *et al.* A guide to machine learning for biologists. **Nature Reviews Molecular Cell Biology**, v. 23, p. 40–55, 2022. Disponível em: <https://doi.org/10.1038/s41580-021-00407-0>. Acesso em: 22 set. 2025.

GRUS, J. **Data science do zero**. Rio de Janeiro: Alta Books, 2016. v. 1.

GUDNADOTTIR, U. *et al.* The vaginal microbiome and the risk of preterm birth: a systematic review and network meta-analysis. **Scientific Reports**, Nature Publishing Group UK London v. 12, n. 1, p. 7926, 2022. Disponível em: <https://doi.org/10.1038/s41598-022-12007-9>. Acesso em: 02 out. 2025.

HARIOM, T.; PURI, S.; LOOKABAUGH, B. **Blueprints de aprendizado de máquina e ciência de dados para finanças: desenvolvendo desde estratégias de trades até robôs Advisors com Python**. Rio de Janeiro: Editora Alta Books, 2024. E-book. p.47. ISBN 9788550821726. Disponível em: <https://app.minhabiblioteca.com.br/reader/books/9788550821726/>. Acesso em: 24 set. 2025.

HO, T. K. Random decision forests. *In*: ANAIS DO 3RD INTERNATIONAL CONFERENCE ON DOCUMENT ANALYSIS AND RECOGNITION (ICDAR '95). 1., 1995, Montreal, QC, Canada. **Anais [...]** Montreal, QC, Canada: IEEE Computer Society Press, 1995. p. 278–282. Disponível em: <https://doi.org/10.1109/ICDAR.1995.598994>. Acesso em: 28 set. 2025.

HOLZINGER, A. *et al.* Causability and explainability of artificial intelligence in medicine. **Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery**, v. 9, n. 4, p. e1312, 2019. Disponível em: <https://doi.org/10.1002/widm.1312>. Acesso em: 09 set. 2025.

HUANG, C. *et al.* Meta-analysis reveals the vaginal microbiome is a better predictor of earlier than later preterm birth. **BMC Biology**, v. 21, n. 1, p. 199, 2023. Disponível em: <https://doi.org/10.1186/s12915-023-01702-2>. Acesso em: 15 ago. 2025.

HULSEN, T. Explainable artificial intelligence (xai): Concepts and challenges in healthcare. **AI**, v. 4, n. 3, p. 652–666, 2023. Disponível em: <https://doi.org/10.3390/ai4030034>. Acesso em: 24 set. 2025.

HYMAN, R. W. *et al.* Diversity of the vaginal microbiome correlates with preterm birth. **Reproductive sciences**, SAGE Publications Sage CA: Los Angeles, CA v. 21, n. 1, p. 32–40, 2014. Disponível em: <https://doi.org/10.1177/1933719113488838>. Acesso em: 05 out. 2025.

KINDSCHUH, W. F. *et al.* Preterm birth is associated with xenobiotics and predicted by the vaginal metabolome. **Nature Microbiology**, v. 8, p. 246–259, 2023. Disponível em: <https://doi.org/10.1038/s41564-022-01293-8>. Acesso em: 16 ago. 2025.

LI, H. *et al.* The vaginal microbial signatures of preterm birth woman. **BMC Pregnancy and Childbirth**, v. 24, n. 1, p. 428, 2024. Disponível em: <https://doi.org/10.1186/s12884-024-06573-1>. Acesso em: 20 ago. 2025.

LIAO, J. *et al.* Microdiversity of the vaginal microbiome is associated with preterm birth. **Nature Communications**, v. 14,, p. 4997, 2023. Disponível em: <https://doi.org/10.1038/s41467-023-40719-7>. Acesso em: 12 ago. 2025.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. **Advances in Neural Information Processing Systems**, v. 30,, 2017. Disponível em: https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html. Acesso em: 17 maio 2026.

LUO, W. *et al.* Guidelines for developing and reporting machine learning predictive models in biomedical research: A multidisciplinary view. **Journal of Medical Internet Research**, v. 18, n. 12, p. e323, 2016. Disponível em: <https://www.jmir.org/2016/12/e323>. Acesso em: 24 set. 2025.

MELO, T. F. M. d. *et al.* Custos diretos da prematuridade e fatores associados ao nascimento e condições maternas. **Revista de Saúde Pública**, v. 56,, p. 49, 2022. Disponível em: <https://doi.org/10.11606/s1518-8787.2022056003657>. Acesso em: 08 set. 2025.

MILLER, T. Explanation in artificial intelligence: Insights from the social sciences. **Artificial Intelligence**, Elsevier v. 267,, p. 1–38, 2019. Disponível em: <https://doi.org/10.1016/j.artint.2018.07.007>. Acesso em: 29 set. 2025.

Ministério da Saúde . **Boletim Epidemiológico**: Perfil epidemiológico dos nascimentos prematuros no brasil, 2012 a 2022. Brasília, DF: , 2024. 55 n. 13. Disponível em: www.gov.br/saude/pt-br/centrais-de-conteudo/publicacoes/boletins/epidemiologicos/edicoes/2024/boletim-epidemiologico-volume-55-no-13.pdf/view. Acesso em: 08 set. 2025.

MURDOCH, W. J. *et al.* Definitions, methods, and applications in interpretable machine learning. **Proceedings of the National Academy of Sciences of the United States of America**, v. 116, n. 44, p. 22071–22080, 2019. Disponível em: <https://doi.org/10.1073/pnas.1900654116>. Acesso em: 24 set. 2025.

NASPOLINI, N. F. *et al.* Exclusive breastfeeding is associated with the gut microbiome maturation in infants according to delivery mode. **Gut Microbes**, v. 17, n. 1, p. 2493900, 2025. Disponível em: <https://doi.org/10.1080/19490976.2025.2493900>. Acesso em: 24 ago. 2025.

NIU, T. *et al.* Decoding student cognitive abilities: a comparative study of explainable ai algorithms in educational data mining. **Scientific Reports**, v. 15,, p. 26862, 2025. Disponível em: <https://doi.org/10.1038/s41598-025-12514-5>. Acesso em: 26 set. 2025.

OBERMEYER, Z. *et al.* Dissecting racial bias in an algorithm used to manage the health of populations. **Science**, American Association for the Advancement of Science v. 366, n. 6464, p. 447–453, 2019. Disponível em: <https://doi.org/10.1126/science.aax2342>. Acesso em: 29 set. 2025.

PAPOUTSOGLU, G. *et al.* Machine learning approaches in microbiome research: challenges and best practices. **Frontiers in Microbiology**, Frontiers Media SA v. 14,, p. 1261889, 2023. Disponível em: <https://doi.org/10.3389/fmicb.2023.1261889>. Acesso em: 01 out. 2025.

PARK, S. *et al.* Predicting preterm birth through vaginal microbiota, cervical length, and wbc using a machine learning model. **Frontiers in Microbiology**, v. 13,, p. 912853, 2022. Disponível em: <https://doi.org/10.3389/fmicb.2022.912853>. Acesso em: 16 ago. 2025.

PERIN, J. *et al.* Global, regional, and national causes of under-5 mortality in 2000-19: an updated systematic analysis with implications for the sustainable development goals. **Lancet Child Adolesc Health**, v. 6, n. 2, p. 106–115, 2022. Epub 2021 Nov 17. Erratum in: Lancet

- Child Adolesc Health. 2022 Jan;6(1):e4. doi: 10.1016/S2352-4642(21)00382-5. Disponível em: [https://doi.org/10.1016/S2352-4642\(21\)00311-4](https://doi.org/10.1016/S2352-4642(21)00311-4). Acesso em: 08 set. 2025.
- QUINLAN, J. R. **C4.5: Programs for Machine Learning**. Elsevier, 2014. ISBN 9780080500584. Disponível em: <https://doi.org/10.1007/BF00993309>. Acesso em: 26 set. 2025.
- QUINLAN, J. R. Induction of decision trees. **Machine Learning**, v. 1,, p. 81–106, 1986. Disponível em: <https://doi.org/10.1007/BF00116251>. Acesso em: 26 set. 2025.
- RAJKOMAR, A.; DEAN, J.; KOHANE, I. Machine learning in medicine. **New England Journal of Medicine**, v. 380, n. 14, p. 1347–1358, 2019. Disponível em: <https://www.nejm.org/doi/full/10.1056/NEJMra1814259>. Acesso em: 22 set. 2025.
- RIBEIRO, M. T.; SINGH, S.; GUESTIN, C. “why should i trust you?” explaining the predictions of any classifier. *In*: ANAIS DO 22ND ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING (KDD '16). 2016, San Francisco, CA, USA. **Anais [...]** San Francisco, CA, USA: ACM Press, 2016. p. 1135–1144. Disponível em: <https://doi.org/10.1145/2939672.2939778>. Acesso em: 29 set. 2025.
- RUDIN, C. Leo breiman, the rashomon effect, and the occam dilemma. **arXiv preprint arXiv:2507.03884**, ,, 2025. Disponível em: <https://doi.org/10.48550/arXiv.2507.03884>. Acesso em: 01 out. 2025.
- RUDIN, C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. **Nature Machine Intelligence**, v. 1,, p. 206–215, 2019. Disponível em: <https://doi.org/10.1038/s42256-019-0048-x>. Acesso em: 09 set. 2025.
- RUDIN, C. *et al.* Interpretable machine learning: Fundamental principles and 10 grand challenges. **Statistical Surveys**, v. 16,, p. 1–85, 2022. Disponível em: <https://doi.org/10.1214/21-SS133>. Acesso em: 16 set. 2025.
- RUSSELL, S. J.; NORVIG, P. **Inteligência Artificial – Uma Abordagem Moderna**. 4. ed. Rio de Janeiro: GEN LTC, 2022. E-book. p.590. ISBN 9788595159495. Disponível em: <https://app.minhabiblioteca.com.br/reader/books/9788595159495/>. Acesso em: 22 set. 2025.
- SALZBERG, S. L. C4.5: Programs for machine learning by J. Ross Quinlan. **Machine Learning**, v. 16,, p. 235–240, 1994. Disponível em: <https://doi.org/10.1007/BF00993309>. Acesso em: 26 set. 2025.
- SARASWAT, D. *et al.* Explainable ai for healthcare 5.0: opportunities and challenges. **IEEE Access**, IEEE v. 10,, p. 84486–84517, 2022. Disponível em: <https://ieeexplore.ieee.org/document/9852458>. Acesso em: 29 set. 2025.
- SHARIFI-HERIS, Z. *et al.* Machine learning approach for preterm birth prediction using health records: Systematic review. **JMIR Medical Informatics**, v. 10, n. 4, p. e33875, 2022. Disponível em: <https://doi.org/10.2196/33875>. Acesso em: 09 set. 2025.
- STIGLIC, G. *et al.* Interpretability of machine learning-based prediction models in healthcare. **Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery**, v. 10, n. 5, p. e1379, 2020. Disponível em: <https://doi.org/10.1002/widm.1379>. Acesso em: 24 set. 2025.
- WITKIN, S. S. The vaginal microbiome, vaginal anti-microbial defence mechanisms and the clinical challenge of reducing infection-related preterm birth. **BJOG: An International Journal of Obstetrics & Gynaecology**, Wiley Online Library v. 122, n. 2, p. 213–218, 2015. Disponível em: <https://doi.org/10.1111/1471-0528.13115>. Acesso em: 04 out. 2025.